


# Tema 4 Distribuciones de probabilidad (I)

1. La distribución binomial.
2. La distribución multinomial
3. La distribución de Poisson
4. La distribución uniforme.
5. La distribución exponencial.
6. La distribución normal.
7. La distribución binormal.
8. La distribución multinormal
9. Distribuciones de Muestreo
  1. La distribución de chi-cuadrado
  2. La distribución t de Student
  3. La distribución F



# 1. La distribución binomial

Estudia los sucesos en los que solo hay dos posibilidades: éxito o fracaso.

- probabilidad de éxito  $\rightarrow p$
- probabilidad de fracaso  $\rightarrow q = 1 - p$


**Ejemplo.** - Lanzamos  $n$  monedas ¿Probabilidad de que  $r$  sean cara?  
 $p = 0.5$ ,  $q = 0.5$

La probabilidad de obtener  $r$  éxitos de un total de  $n$  intentos viene dada por:

$$B(r, n, p) = \binom{n}{r} p^r (1-p)^{n-r} = \frac{n!}{r!(n-r)!} p^r (1-p)^{n-r}$$

Número de permutaciones  
equivalentes para un resultado

Probabilidad de un resultado  
particular, e.g. "CCXC"



## Normalización

$$\sum_{r=0}^n B(r, n, p) = \sum_{r=0}^n \binom{n}{r} p^r (1-p)^{n-r} = \sum_{r=0}^n \binom{n}{r} p^r q^{n-r} = (p+q)^n = (p+1-p)^n = 1$$

# 1. La distribución binomial

## Valor medio.-

$$\begin{aligned}\mu = E[r] &= \sum_{r=0}^n r B(r, n, p) = \sum_{r=0}^n r \frac{n!}{r!(n-r)!} p^r (1-p)^{n-r} = np \sum_{r=1}^n \frac{(n-1)!}{(r-1)!(n-r)!} p^{r-1} (1-p)^{n-r} = \left| \begin{matrix} s = r-1 \\ m = n-1 \end{matrix} \right| = \\ &= np \sum_{s=0}^m \frac{(m)!}{(s)!(m-s)!} p^s (1-p)^{m-s} = np \sum_{s=0}^m \binom{m}{s} p^s (1-p)^{m-s} = np \quad \mu = np\end{aligned}$$

## Varianza:

$$\sigma^2 = V[r] = np(1-p)$$

## Skewness

$$\gamma_1 = \frac{1-2p}{\sqrt{np(1-p)}}$$

## Kurtosis

$$\gamma_2 = \frac{1-6p(1-p)}{np(1-p)}$$

## Función característica

$$\phi(t) = [pe^{it} + (1-p)]^n$$

**Ejemplo:** Sucesos en un histograma:

p.- Probabilidad de caer en un determinado *bin*

q.- Probabilidad de no caer

$$V[r] = np(1-p) = n\hat{p}(1-\hat{p}) = n \frac{r}{n} \left(1 - \frac{r}{n}\right) = r \left(1 - \frac{r}{n}\right)$$

$$\sigma(r) = \sqrt{r \left(1 - \frac{r}{n}\right)}$$




Si en vez de  $r$  utilizamos la variable  $r/n$ :


$$E\left[\frac{r}{n}\right] = \frac{1}{n} E[r] = p \quad ; \quad V\left[\frac{r}{n}\right] = \frac{1}{n^2} V[r] = \frac{p(1-p)}{n}$$

# 1. La distribución binomial


$p=0.1, N=4$




$p=0.5, N=4$




$p=0.9, N=4$




$p=0.1, N=100$



$p=0.5, N=100$



$p=0.9, N=100$



## 2. La distribución multinomial

Generalización de la distribución binomial para más de 2 resultados posibles.

- Sucesos clasificados por categorías o clases  $A_1, A_2, \dots, A_k$
- Probabilidad  $p_i$  de obtener un suceso en la clase  $A_i$
- Probabilidades normalizadas

$$\sum_{i=1}^k p_i = 1$$

La probabilidad de obtener  $r_1, r_2, \dots, r_k$  sucesos en las correspondientes clases viene dada por:

$$M(\bar{r}, n, \bar{p}) = \frac{n!}{r_1! r_2! \cdots r_k!} p_1^{r_1} p_2^{r_2} \cdots p_k^{r_k}$$

Expresión de la distribución multinomial de la variable  $\bar{r} = \{r_1, r_2, \dots, r_k\}$  para los parámetros  $n$  y  $\bar{p} = \{p_1, p_2, \dots, p_k\}$

Los valores de  $r_i$  no son independientes puesto que se cumple que:

$$\sum_{i=1}^k r_i = n$$

## 2. La distribución multinomial

### Valor medio

$$E[r_i] = np_i$$

### Varianza

$$V(r_i) = np_i(1 - p_i)$$

### Covarianza

$$\text{cov}(r_i, r_j) = -np_i p_j$$

### Correlación

$$\rho(r_i, r_j) = \frac{\text{cov}(r_i, r_j)}{\sigma_i \sigma_j} = -\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}}$$

### Función característica

$$\phi(t_1, t_2, \dots, t_k) = \left( p_1 e^{it_1} + p_2 e^{it_2} + \dots + p_k e^{it_k} \right)^n$$

**Ejemplo** Sucesos distribuidos en los bins de un histograma

$p_i$  Probabilidad de que un suceso caiga en el bin  $i$ -ésimo

$$E[r_i] = np_i \quad V(r_i) = np_i(1 - p_i)$$

$r_i$  Número de sucesos en el bin  $i$ -ésimo

Si  $p_i \ll 1$  correspondiente a una distribución con muchos bins

$$V(r_i) = np_i(1 - p_i) \approx np_i = r_i \quad \longrightarrow \quad \sigma(r_i) = \sqrt{r_i}$$

## 2. La distribución multinomial

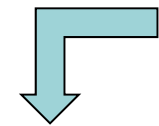
Se puede considerar que el número total de sucesos  $n$  no es una cantidad fija  
Supongamos que los valores de los números de sucesos en cada bin son independientes y poissonianos:

$$\sigma(r_i) = \sqrt{r_i}$$

El número total de sucesos también será una variable de Poisson

$$\sum_{i=1}^k r_i = n$$

La pdf será entonces el producto de una Multinomial por una de Poisson:

$$\sum_{i=1}^k p_i = 1$$


$$\begin{aligned} P(r_1, r_2, \dots, r_k; n) &= M(r, n, p) P(n; \mu) = \frac{n!}{r_1! r_2! \dots r_k!} p_1^{r_1} p_2^{r_2} \dots p_k^{r_k} \frac{\mu^n}{n!} e^{-\mu} = \\ &= \frac{p_1^{r_1} p_2^{r_2} \dots p_k^{r_k}}{r_1! r_2! \dots r_k!} \mu^{r_1 + r_2 + \dots + r_k} e^{-\mu \sum_{i=1}^k p_i} = \left( \frac{(\mu p_1)^{r_1}}{r_1!} e^{-\mu p_1} \right) \left( \frac{(\mu p_2)^{r_2}}{r_2!} e^{-\mu p_2} \right) \dots \left( \frac{(\mu p_k)^{r_k}}{r_k!} e^{-\mu p_k} \right) \end{aligned}$$

La pdf es el producto de  $k$  distribuciones de Poisson de variables  $r_i$  con valor medio  $\mu p_i$

Los sucesos de cada bin son variables poissonianas independientes con:

$$E[r_i] = V(r_i) = \sqrt{r_i}$$

# 3. La distribución de Poisson

Límite natural de la distribución binomial cuando  $n \rightarrow \infty$  y  $p \rightarrow 0$  de manera que el producto se mantiene finito  $\mu = np$

$$B(r, n, p) = \binom{n}{r} p^r (1-p)^{n-r} = \frac{n!}{r!(n-r)!} p^r (1-p)^{n-r} = \left| \begin{matrix} n \rightarrow \infty \\ p \rightarrow 0 \end{matrix} \right| \approx \frac{(pn)^r}{r!} e^{-\mu}$$

$$\frac{n!}{(n-r)!} = n(n-1)(n-2)\cdots(n-r+1) \approx n^r$$

$$(1-p)^{-r} \approx 1 + rp \approx 1$$

$$\lim_{p \rightarrow 0} (1-p)^n = \lim_{p \rightarrow 0} \left[ (1-p)^{1/p} \right]^{np} = e^{-\mu}$$

$$P(r, \mu) = \frac{\mu^r}{r!} e^{-\mu}$$



## Normalización

$$\sum_{r=0}^{\infty} P(r, \mu) = \sum_{r=0}^{\infty} \frac{\mu^r}{r!} e^{-\mu} = e^{-\mu} \sum_{r=0}^{\infty} \frac{\mu^r}{r!} = e^{-\mu} e^{\mu} = 1$$

## Valor medio.-

$$E[r] = \sum_{r=0}^{\infty} r P(r, \mu) = \sum_{r=0}^{\infty} r \frac{\mu^r}{r!} e^{-\mu} = \mu e^{-\mu} \sum_{r=1}^{\infty} \frac{\mu^{r-1}}{(r-1)!} = \mu e^{-\mu} \sum_{s=0}^{\infty} \frac{\mu^s}{s!} = \mu$$


$$s = r - 1$$



# 3. La distribución de Poisson

## Varianza:

$$\sigma^2 = V[r] = \mu$$



$$\sigma = \sqrt{\mu}$$

!!! En la distribución de Poisson la media y la varianza coinciden !!!

## Skewness

$$\gamma_1 = \frac{1}{\sqrt{\mu}}$$

Se hace menos asimétrica a medida que aumenta  $\mu$

## Kurtosis










$$\gamma_2 = \frac{1}{\mu}$$

Tiende a la distribución de Gauss cuando  $\mu \rightarrow \infty$

## Función característica

$$\phi(t) = \exp[\mu(e^{it} - 1)]$$

19/10/2015



Distribuciones de Probabilidad (I)

# 3. La distribución de Poisson

Supongamos un detector que registra sucesos en un intervalo  $t$ .

$\lambda \rightarrow$  Número medio de sucesos detectados por unidad de tiempo es constante.

$\lambda \Delta t \rightarrow$  Número medio de sucesos detectados en  $\Delta t$


La distribución de Poisson solo es aplicable cuando se dan las siguientes hipótesis:

1. La probabilidad de encontrar un suceso en  $\Delta t$  es proporcional al tamaño de  $\Delta t$ .
2. Solo puede haber un suceso como mucho en  $[t, t+\Delta t]$
3. La detección en el intervalo  $[t, t+\Delta t]$  es independiente de la detección en cualquier otro intervalo.

¿Probabilidad de detectar un suceso en  $[t, t+\Delta t]$ ?  $P_1(\Delta t) = \lambda \Delta t$  (Hipótesis 1 y 2)

¿Probabilidad de detectar ningún suceso en  $[t, t+\Delta t]$ ?  $P_0(\Delta t) = 1 - P_1(\Delta t) = 1 - \lambda \Delta t$

¿Cuál es la probabilidad de que ocurran  $r$  sucesos en  $t+\Delta t$ ?  $\left\{ \begin{array}{l} 1) r \text{ en } t \text{ y } 0 \text{ en } \Delta t \\ 2) r-1 \text{ en } t \text{ y } 1 \text{ en } \Delta t \end{array} \right.$



$P_r(t + \Delta t) = P_r(t) P_0(\Delta t) + P_{r-1}(t) P_1(\Delta t) = P_r(t)(1 - \lambda \Delta t) + P_{r-1}(t) \lambda \Delta t$  (Hipótesis 3)

$$\frac{dP_r(t)}{dt} = \frac{P_r(t + dt) - P_r(t)}{dt} = -\lambda P_r(t) + \lambda P_{r-1}(t) = \lambda [P_{r-1}(t) - P_r(t)]$$

Ecuación diferencial cuya solución es:

$$P_r(t) = \frac{(\lambda t)^r}{r!} e^{-\lambda t} = \frac{\mu^r}{r!} e^{-\mu}$$

### 3. La distribución de Poisson

La suma de variables aleatorias que se distribuyen según Poisson es también una variable aleatoria que se distribuye según Poisson.

#### Ejemplo fuente radiactiva con fondo

Fuente radiactiva  $\rightarrow$  emite  $\lambda_X$  partículas por unidad de tiempo  $\mu_X = \lambda_X t$

Fondo radiactivo  $\rightarrow$  emite  $\lambda_b$  partículas por unidad de tiempo  $\mu_b = \lambda_b t$

$$\begin{aligned} P(r; \mu_X; \mu_b) &= \sum_{r_b=0}^r P_X(r-r_b; \mu_X) P_b(r_b; \mu_b) = \sum_{r_b=0}^r \left[ \frac{1}{(r-r_b)!} (\mu_X)^{r-r_b} e^{-\mu_X} \right] \left[ \frac{1}{(r_b)!} (\mu_b)^{r_b} e^{-\mu_b} \right] = \\ &= \frac{e^{-\mu_X} e^{-\mu_b}}{r!} \sum_{r_b=0}^r \frac{r!}{r_b! (r-r_b)!} (\mu_X)^{r-r_b} (\mu_b)^{r_b} = \frac{e^{-(\mu_X + \mu_b)}}{r!} \sum_{r_b=0}^r \binom{r}{r_b} (\mu_X)^{r-r_b} (\mu_b)^{r_b} \\ &= e^{-(\mu_X + \mu_b)} \frac{(\mu_X + \mu_b)^r}{r!} \end{aligned}$$

**Ley de adición de variables poissonianas.**- La suma de cualquier número de variables de Poisson independientes es una nueva variable de Poisson con valor medio igual a la suma de los valores medios de cada variable

# 4. La distribución uniforme

La distribución uniforme describe una variable aleatoria para la cual, la densidad de probabilidad es constante

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$
$$f(x) = 0, \quad \text{otros valores}$$

## Función cumulativa

$$F(x) = \int_a^x f(x') dx' = \int_a^x \frac{1}{(b-a)} dx' = \frac{(x-a)}{(b-a)}; \quad a \leq x \leq b$$

## Valor esperado

$$E[x] = \int_a^b x f(x) dx = \frac{1}{(b-a)} \left[ \frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{(a+b)}{2}$$

## Varianza

$$V[x] = E[x^2] - E[x]^2 = \int_a^b (x - E[x])^2 f(x) dx = \frac{(b-a)^2}{12}$$

## Skewness


$$\gamma_1 = 0$$

## Kurtosis


$$\gamma_2 = -1.2$$

## Función característica

$$\phi(t) = \frac{e^{itb} - e^{ita}}{it(b-a)}$$



Distribución uniforme



Función cumulativa

## 4. La distribución uniforme


Cualquier distribución de variable continua se puede transformar en una distribución uniforme a partir de la función acumulativa:

$$F(x) = \int_{-\infty}^x f(x') dx'$$

Mediante el siguiente cambio de variable:  $u = F(x)$

La pdf de la nueva variable  $u$  viene dada por:

$$g(u) = f(x) \left| \frac{dx}{du} \right| = \frac{f(x)}{\left| \frac{du}{dx} \right|} = \frac{f(x)}{\left| \frac{dF(x)}{dx} \right|} = \frac{f(x)}{|f(x)|} = 1$$



$$0 \leq u \leq 1$$

Especialmente útil para:

- La generación de números aleatorios por Monte Carlo
- Test de hipótesis mediante la distribución de chi-cuadrado

# 5. La distribución exponencial

La distribución exponencial viene dada por:

Función cumulativa

$$f(x, \lambda) = \lambda e^{-\lambda x}, \quad 0 \leq x \leq \infty$$

$$F(x) = \int_0^x f(x') dx' = \int_0^x \lambda e^{-\lambda x'} dx' = -e^{-\lambda x'} \Big|_0^x = 1 - e^{-\lambda x}$$

La variable aleatoria siempre es positiva

Valor esperado

$$E[x] = \int_0^{\infty} x f(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} x e^{-\lambda x} dx = \frac{1}{\lambda}$$

Varianza

$$V[x] = E[x^2] - E[x]^2 = \frac{1}{\lambda^2}$$

Relación con la distribución de Poisson

Skewness

$$\gamma_1 = 2$$

Supongamos un experimento de conteo de sucesos que se distribuyen según Poisson, y que el primero de ellos tiene lugar en el intervalo  $[t, t+dt]$ , i.e.:

- Ha habido 0 sucesos hasta  $t$
- Ha habido un suceso en  $[t, t+dt]$ ,

Kurtosis

$$\gamma_2 = 6$$

$$\left. \begin{aligned} P_0(t) &= \frac{(\lambda t)^r}{r!} e^{-\lambda t} = e^{-\lambda t} \\ P_1(dt) &= \lambda dt \end{aligned} \right\} \longrightarrow P_0(t) P_1(dt) = e^{-\lambda t} \lambda dt = \lambda e^{-\lambda t} dt = f(t) dt$$

$$f(t) = \lambda e^{-\lambda t}$$

Función característica

$$\phi(t) = \left(1 - \frac{it}{\lambda}\right)^{-1}$$

**“La distribución de las distancias entre sucesos consecutivos de Poisson es una distribución exponencial”**

# 6. La distribución normal o de Gauss

Es la distribución de probabilidad más importante en el análisis de datos.  
Distribución de los errores experimentales (Teorema del límite central).

$$N(x, \mu, \sigma^2) \equiv \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \quad -\infty \leq x \leq \infty$$

## Valor esperado

$$E[x] = \int_{-\infty}^{+\infty} x N(x, \mu, \sigma) dx = \mu$$

## Varianza

$$V[x] = \int_{-\infty}^{\infty} (x - \mu)^2 N(x, \mu, \sigma) dx = \sigma^2$$

## Skewness

$$\gamma_1 = 0$$

## Kurtosis

$$\gamma_2 = 0$$

## Función característica

$$\phi(t) = \exp \left[ it\mu - \frac{\sigma^2 t^2}{2} \right]$$


19/10/2015

## La distribución normal estándar

Cambio de variable  $\rightarrow y = \frac{x - \mu}{\sigma} \quad g(y)dy = f(x)dx$

$$g(y) = \frac{f(x)}{\left| \frac{dy}{dx} \right|} = \sigma f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

$$N(y, 0, 1) \equiv \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$




**Distribución normal de valor medio 0 y desviación típica 1**

# 6. La distribución normal estándar

La distribución normal estándar acumulativa viene dada por

$$G(y) = \int_{-\infty}^y N(y') dy' = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{y'^2}{2}} dy'$$



Función tabulada que nos permite calcular contenidos de probabilidad de un intervalo dado

$$\begin{aligned} P(a \leq x \leq b) &= P(x \leq b) - P(x \leq a) = P\left(\frac{x - \mu}{\sigma} \leq \frac{b - \mu}{\sigma}\right) - P\left(\frac{x - \mu}{\sigma} \leq \frac{a - \mu}{\sigma}\right) = \\ &= \int_{-\infty}^{(b-\mu)/\sigma} g(y') dy' - \int_{-\infty}^{(a-\mu)/\sigma} g(y') dy' = G\left(\frac{b - \mu}{\sigma}\right) - G\left(\frac{a - \mu}{\sigma}\right) \end{aligned}$$

La probabilidad para diferentes  $\sigma$ :

$$P(\mu - \sigma \leq x \leq \mu + \sigma) = 2G(1) - 1 = 0.6827$$

$$P(\mu - 2\sigma \leq x \leq \mu + 2\sigma) = 2G(2) - 1 = 0.9545$$

$$P(\mu - 3\sigma \leq x \leq \mu + 3\sigma) = 2G(3) - 1 = 0.9973$$

La probabilidad para diferentes  $\sigma$ :

$$P(\mu - 1.645\sigma \leq x \leq \mu + 1.645\sigma) = 0.90$$

$$P(\mu - 1.960\sigma \leq x \leq \mu + 1.960\sigma) = 0.95$$

$$P(\mu - 2.576\sigma \leq x \leq \mu + 2.576\sigma) = 0.99$$

$$P(\mu - 3.29\sigma \leq x \leq \mu + 3.29\sigma) = 0.999$$

$$G(-y) = 1 - G(y)$$

La función cumulativa de la distribución normal está relacionada con la función error

$$G(z) = \frac{1}{2} \left[ 1 + \operatorname{erf} \left( \frac{z}{\sqrt{2}} \right) \right]; \quad z > 0$$

$$G(z) = \frac{1}{2} \left[ 1 - \operatorname{erf} \left( -\frac{z}{\sqrt{2}} \right) \right]; \quad z < 0$$

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-x^2} dx$$



# 6. La distribución normal estándar


## ROOT Functions

Double\_t p = TMath::Freq (Double\_t z) ➔ Equivale a:  $G(z) = \int_{-\infty}^z N(z') dz' = p$

Double\_t z = TMath::NormQuantile (Double\_t p) ➔ Equivale a su inversa:  $G^{-1}(p) = z$

$$P(2\text{sided}) = 2P(1\text{sided}) - 1$$

z (σ)	P (1-sided)	P (2-sided)
1.0	0.841	0.683
2.0	0.977	0.955
3.0	0.999	0.997
1.281	0.9	0.8
1.645	0.95	0.9
2.326	0.99	0.98




**P(1sided)**

$$2\sigma \Rightarrow p = 0.977$$

**P(2sided)**

$$2\sigma \Rightarrow p = 0.955$$



# 6. La distribución normal o de Gauss

## Teorema de adición de variables normales

Una combinación lineal de variables aleatorias distribuidas normalmente, es también una variable aleatoria distribuida normalmente

### A) Producto por una constante

Si  $x \rightarrow N(\mu, \sigma^2)$  ¿ $y = ax$ ? siendo  $a$  una constante. (Cambio de variable)  $y = ax$

$$\left. \begin{aligned} f(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\ g(y)dy &= f(x)dx \end{aligned} \right\} \longrightarrow g(y) = \frac{f(x)}{\left| \frac{dy}{dx} \right|} = \frac{1}{\sqrt{2\pi\sigma a}} e^{-\frac{(y-a\mu)^2}{2\sigma^2 a^2}} = N(a\mu, a^2\sigma^2)$$

Luego  $ax$  se distribuye como una gaussiana de media  $a\mu$  y varianza  $(a\sigma)^2$

### B) Suma de dos variables

Si  $x \rightarrow N(\mu_x, \sigma_x^2)$ ,  $y \rightarrow N(\mu_y, \sigma_y^2)$  ambas independientes ¿ $z = x + y$ ?

$x, y$  variables aleatorias independientes

$$\begin{aligned} \phi_z(t) &= E[e^{itz}] = E[e^{it(x+y)}] = E[e^{itx} \cdot e^{ity}] = \int e^{itx} \cdot e^{ity} f(x, y) dx dy = \\ &= \int e^{itx} \cdot e^{ity} f_x(x) f_y(y) dx dy = \int e^{itx} f_x(x) dx \int e^{ity} f_y(y) dy = \phi_x(t) \phi_y(t) \end{aligned}$$

$$\phi_z(t) = \phi_x(t) \phi_y(t) = e^{i\mu_x t - \frac{1}{2}\sigma_x^2 t^2} e^{i\mu_y t - \frac{1}{2}\sigma_y^2 t^2} = e^{i(\mu_x + \mu_y)t - \frac{1}{2}(\sigma_x^2 + \sigma_y^2)t^2} = e^{i\mu t - \frac{1}{2}\sigma^2 t^2}$$

$$z \rightarrow N(\mu, \sigma^2) \quad \mu = \mu_x + \mu_y; \sigma^2 = \sigma_x^2 + \sigma_y^2$$

# 6. La distribución normal o de Gauss

## C) Combinación lineal de dos variables

Si  $x_1 \rightarrow N(\mu_1, \sigma_1^2)$   
Si  $x_2 \rightarrow N(\mu_2, \sigma_2^2)$  }  $\longrightarrow$  ¿ $x = a_1x_1 + a_2x_2$  ? siendo  $a_1$  y  $a_2$  constantes.

$$x = a_1x_1 + a_2x_2 \rightarrow N(a_1\mu_1 + a_2\mu_2, a_1^2\sigma_1^2 + a_2^2\sigma_2^2)$$

Trivial  
A),B)

## D) Caso general

$$x = a_1x_1 + a_2x_2 + \cdots + a_nx_n$$

tal que  $x_1, x_2, \dots, x_n$  son variables aleatorias e independientes distribuidas normalmente

$$\left. \begin{array}{l} x_1 \rightarrow N(\mu_1, \sigma_1^2) \\ x_2 \rightarrow N(\mu_2, \sigma_2^2) \\ \dots \\ x_n \rightarrow N(\mu_n, \sigma_n^2) \end{array} \right\} x \rightarrow N(\mu, \sigma^2) \quad \text{con} \quad \left\{ \begin{array}{l} \mu = \sum_{i=1}^n a_i \mu_i \\ \sigma^2 = \sum_{i=1}^n a_i^2 \sigma_i^2 \end{array} \right.$$

# 7. La distribución binormal

La distribución normal en dos dimensiones o distribución binormal viene dada por:

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{Q}{2}} \quad \text{con} \quad Q = \frac{1}{1-\rho^2} \left[ \left( \frac{x_1 - \mu_1}{\sigma_1} \right)^2 + \left( \frac{x_2 - \mu_2}{\sigma_2} \right)^2 - 2\rho \left( \frac{x_1 - \mu_1}{\sigma_1} \right) \left( \frac{x_2 - \mu_2}{\sigma_2} \right) \right]$$

## Función característica


$$\Phi(t_1, t_2) = \exp \left[ it_1\mu_1 + it_2\mu_2 + \frac{1}{2} \left[ (it_1)^2 \sigma_1^2 + (it_2)^2 \sigma_2^2 + (it_1)(it_2) 2\rho\sigma_1\sigma_2 \right] \right]$$

$$E[x_1] = \left. \frac{\partial \Phi}{\partial (it_1)} \right|_{t_1=t_2=0} = \mu_1$$

$$E[x_1 x_2] = \left. \frac{\partial^2 \Phi}{\partial (it_1) \partial (it_2)} \right|_{t_1=t_2=0} = \mu_1 \mu_2 + \rho \sigma_1 \sigma_2$$

$$E[x_1^2] = \left. \frac{\partial^2 \Phi}{\partial (it_1)^2} \right|_{t_1=t_2=0} = \mu_1^2 + \sigma_1^2$$

$$\rho(x_1, x_2) = \frac{E[x_1 x_2] - E[x_1]E[x_2]}{\sigma_1 \sigma_2} = \frac{\mu_1 \mu_2 + \rho \sigma_1 \sigma_2 - \mu_1 \mu_2}{\sigma_1 \sigma_2} = \rho$$



Si  $\rho=0 \rightarrow$  la pdf y la función característica factorizan:



$$f(x_1, x_2) = \left[ \frac{1}{\sigma_1 \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x_1 - \mu_1}{\sigma_1} \right)^2} \right] \left[ \frac{1}{\sigma_2 \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x_2 - \mu_2}{\sigma_2} \right)^2} \right]$$

$$\Phi(t_1, t_2) = \exp \left[ it_1 \mu_1 + \frac{1}{2} (it_1)^2 \sigma_1^2 \right] \exp \left[ it_2 \mu_2 + \frac{1}{2} (it_2)^2 \sigma_2^2 \right]$$

# 7. La distribución binormal

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{Q}{2}}$$

$$Q = \frac{1}{1-\rho^2} \left[ \left( \frac{x_1 - \mu_1}{\sigma_1} \right)^2 + \left( \frac{x_2 - \mu_2}{\sigma_2} \right)^2 - 2\rho \left( \frac{x_1 - \mu_1}{\sigma_1} \right) \left( \frac{x_2 - \mu_2}{\sigma_2} \right) \right]$$

Contornos de densidad de probabilidad constante se obtienen fijando el exponente a una constante

Cuando  $Q=1$  los valores extremos de la elipse son  $\mu_1 \pm \sigma_1$  y  $\mu_2 \pm \sigma_2$

Como la matriz de covarianza es simétrica existe una transformación unitaria que la diagonaliza

$$U = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \quad \text{Nueva matriz de covarianza} \rightarrow UVU^T$$



$$\sigma_u^2 = \frac{\sigma_1^2 \cos^2 \theta - \sigma_2^2 \sin^2 \theta}{\cos^2 \theta - \sin^2 \theta}$$

$$\sigma_v^2 = \frac{\sigma_2^2 \cos^2 \theta - \sigma_1^2 \sin^2 \theta}{\cos^2 \theta - \sin^2 \theta}$$

$$\sigma_1^2 = \sigma_u^2 \cos^2 \theta + \sigma_v^2 \sin^2 \theta$$

$$\sigma_2^2 = \sigma_v^2 \cos^2 \theta + \sigma_u^2 \sin^2 \theta$$

$$\rho = \sin \theta \cos \theta \frac{\sigma_u^2 - \sigma_v^2}{\sigma_1 \sigma_2}$$



Si  $\rho$  es grande (elipse fina) conocer  $\sigma_1, \sigma_2$  no da una visión realista de lo cerca que está  $x, y$  de  $\mu_1, \mu_2$

# 8. La distribución multinormal

La distribución normal en n dimensiones o distribución multinormal viene dada por:

$$f(x_1, x_2, \dots, x_n) = C e^{-\frac{Q}{2}} \quad \text{con} \quad Q = \sum_{i=1}^n \sum_{j=1}^n c_{ij} \left( \frac{x_i - \mu_i}{\sigma_i} \right) \left( \frac{x_j - \mu_j}{\sigma_j} \right)$$

Forma compacta:

$$f(\bar{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |V|^{\frac{1}{2}}} e^{-\frac{1}{2}(\bar{x} - \bar{\mu})^T V^{-1}(\bar{x} - \bar{\mu})}$$

$$\text{Con} \begin{cases} \bar{x} = \{x_1, x_2, \dots, x_n\} \\ \bar{\mu} = \{\mu_1, \mu_2, \dots, \mu_n\} \\ V \text{ matriz de covarianza} \\ |V| \neq 0, \quad V, V^{-1} \text{ definidas positivas} \end{cases} \quad V = \begin{pmatrix} \sigma_1^2 & \dots & \rho_{1n} \sigma_1 \sigma_n \\ \vdots & \ddots & \vdots \\ \rho_{1n} \sigma_n \sigma_1 & \dots & \sigma_n^2 \end{pmatrix}$$

## Función característica

$$\Phi(\bar{t}) = \exp \left[ (\bar{it})^T \bar{\mu} + \frac{1}{2} (\bar{it})^T V (\bar{it}) \right]$$

$$E[x_r] = \left. \frac{\partial \Phi}{\partial (it_r)} \right|_{\bar{t}=0} = \mu_r$$

$$E[x_r x_s] = \left. \frac{\partial^2 \Phi}{\partial (it_r) \partial (it_s)} \right|_{\bar{t}=0} = \mu_r \mu_s + \rho \sigma_r \sigma_s,$$

$$r, s = 1, 2, \dots, n$$

Si V es diagonal  $\rightarrow$  las variables no están correlacionadas ( $\rho=0$ )  $\rightarrow$  No hay términos de mezcla en el exponente y la pdf se puede factorizar en n pdfs unidimensionales  $\rightarrow$  las variables son independientes:

$$f(\bar{x}) = \left[ \frac{1}{\sigma_1 \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x_1 - \mu_1}{\sigma_1} \right)^2} \right] \left[ \frac{1}{\sigma_2 \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x_2 - \mu_2}{\sigma_2} \right)^2} \right] \dots \left[ \frac{1}{\sigma_n \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x_n - \mu_n}{\sigma_n} \right)^2} \right]$$

**Las variables de una distribución multinormal son independientes si y solo si la matriz de covarianza es diagonal**

