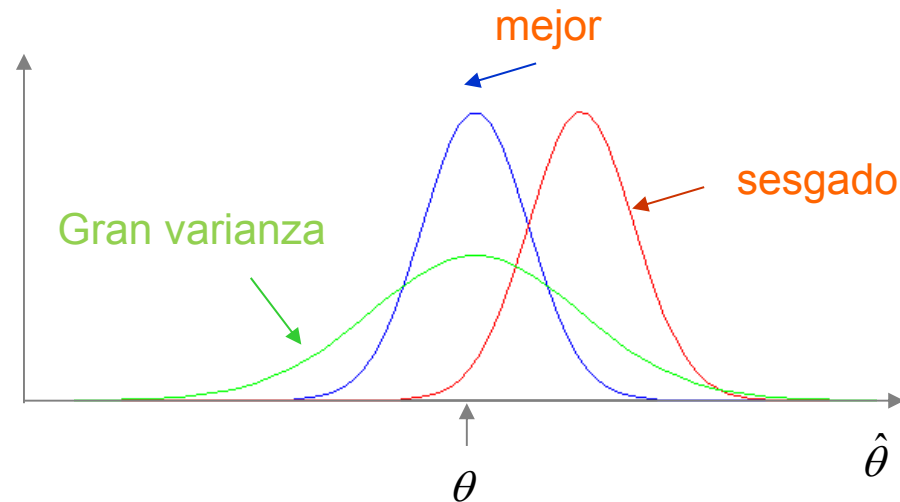



Tema 7 Estimación de parámetros

1. Introducción.
2. Propiedades de los estimadores
3. Información y “*likelihood*”
4. Límite de mínima varianza. Desigualdad de Raó-Cramér
5. Eficiencia de un estimador
6. Ejemplo




1.- Introducción

¿Cuál es la diferencia entre Probabilidad y Estadística?



Dada una distribución de probabilidad con sus parámetros conocidos ¿qué podemos decir sobre los datos?



Realizado un experimento y obtenidos unos datos ¿qué podemos decir sobre la teoría? ¿Qué podemos decir sobre la pdf y sus parámetros a partir de los datos?

Estimación de parámetros.- Procedimiento para obtener \vec{p} a partir de $D(\vec{x})$

1. Introducción. Definiciones

Supongamos que tenemos un conjunto de n medidas x_i como resultado de un experimento y queremos medir un parámetro cuyo valor verdadero pero desconocido es θ .

Estadístico

Un **estadístico** es cualquier función de las observaciones de una muestra, $\phi(x_i)$, y que no depende de ninguna de las características desconocidas de la población de origen (**parent pdf**).

Estimador

Un **estimador** es un procedimiento, método, o estadístico que proporciona un valor del parámetro o propiedad de la distribución, en función de las observaciones de la muestra.

A la estimación obtenida en general se le llama con un acento circunflejo, $\hat{\theta}$, es decir, se dice entonces que $\hat{\theta}$ es el estimador del parámetro θ

Estimación de parámetros

Dado un conjunto de datos, **estimar un parámetro** consiste en determinar un valor tan cercano como sea posible al valor verdadero

Estimación de intervalos

Dado un conjunto de datos, **estimar un intervalo** consiste en determinar el rango de valores que con mayor probabilidad contiene al valor verdadero


2.- Propiedades de los estimadores

Puesto que un estadístico se calcula a partir de variables aleatorias, cualquier estimador basado en un estadístico es también una variable aleatoria y se distribuirá según una distribución de probabilidad i.e., si repetimos el experimento, las estimaciones obtenidas seguirán una pdf:

$$g(\hat{\theta}; \theta)$$

La calidad o mérito de un estimador se mide por las propiedades de las distribuciones a que dan lugar.

En general, un buen estimador debe producir estimaciones que no se desvíen sistemáticamente (**unbiased**) del valor verdadero, su exactitud aumente con el número de medidas (eficiente) y tenga la mínima varianza.



2.- Propiedades de los estimadores

Sesgo (*Bias*)

Para un estimador que utiliza un conjunto de n observaciones, se define el sesgo o *bias* b_n como la diferencia entre su valor esperado y el valor verdadero del parámetro

$$b_n(\hat{\theta}) = E[\hat{\theta}] - \theta = E[\hat{\theta} - \theta]$$

Se dice que un estimador es no sesgado (unbiased) si para todo n y todo θ :

$$b_n(\hat{\theta}) = 0 \quad \longrightarrow \quad E[\hat{\theta}] = \theta$$

Ejemplo

Media.- En general la media muestral es un estimador no sesgado de la media verdadera de la distribución

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \quad \longrightarrow \quad E[\hat{\mu}] = E[\bar{x}] = E\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n} \sum_{i=1}^n E[x_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu$$

2.- Propiedades de los estimadores

Varianza.- Si conocemos la media verdadera μ

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \quad \longrightarrow \quad E[S^2] = E\left[\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2\right] = \frac{1}{n} \{nE[x^2] - 2\mu nE[x] + n\mu^2\} = E[x^2] - \mu^2 = \sigma^2$$

Se dice que S^2 es un estimador no sesgado de la varianza σ^2

Varianza.- Si no conocemos la media verdadera y la estimamos a partir del valor medio $\hat{\mu} = \bar{x}$

$$S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2$$


$$E\left[\sum_{i=1}^n x_i^2\right] = nE[x^2] = n(\sigma^2 + \mu^2)$$

$$E\left[\left(\sum_{i=1}^n x_i\right)^2\right] = V\left[\sum_{i=1}^n x_i\right] + \left(E\left[\sum_{i=1}^n x_i\right]\right)^2 = n\sigma^2 + n^2\mu^2$$

$$E[S_x^2] = E\left[\frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i\right)^2\right] = \frac{1}{n} \left(E\left[\sum_{i=1}^n x_i^2\right] - \frac{1}{n} E\left[\left(\sum_{i=1}^n x_i\right)^2\right]\right) = \frac{1}{n} \left(n(\sigma^2 + \mu^2) - \frac{1}{n}(n\sigma^2 + n^2\mu^2)\right) = \frac{1}{n}(n-1)\sigma^2$$

Se dice que S_x^2 es un estimador sesgado de la varianza σ^2

2.- Propiedades de los estimadores

Varianza: La anchura de los datos alrededor de la media muestral siempre es menor que la anchura alrededor de la media verdadera  S_x^2 siempre subestima la varianza

Un estimador no sesgado de la varianza vendrá dado por tanto por:

$$s^2 = \frac{n}{n-1} S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

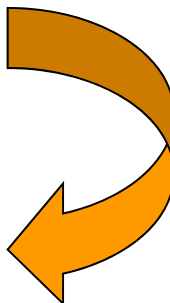
Además, si la pdf es gaussiana o $n \rightarrow \infty$ (CLT) la variable:

$$\frac{(n-1)s^2}{\sigma^2} \text{ se distribuye como } \chi^2(n-1)$$

(Tema 6 Distribuciones de Probabilidad (II), pag. 12)

Si las variables son gaussianas otra forma de verlo es la siguiente:

$$z_i = \frac{x_i - \bar{x}}{\sigma} \quad \text{orange arrow} \quad \sum_{i=1}^n z_i^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{Se distribuye como una variable } \chi^2(n-1)$$

$$E[s^2] = E\left[\frac{\sigma^2}{n-1} \sum_{i=1}^n z_i^2\right] = E\left[\frac{\sigma^2}{n-1} \chi^2(n-1)\right] = \frac{\sigma^2}{n-1} E[\chi^2(n-1)] = \sigma^2$$


2.- Propiedades de los estimadores

Consistencia

Un estimador se dice que es consistente cuando converge al valor verdadero a medida que aumenta el número de observaciones.

Definición

Un estimador $\hat{\theta}$ de un parámetro θ es consistente si para todo $\varepsilon > 0$ (no importa lo pequeño que sea)

$$\lim_{n \rightarrow \infty} P\left(\left|\hat{\theta} - \theta\right| \geq \varepsilon\right) = 0$$

Si el estimador $\hat{\theta}$ es el promedio de datos que se distribuyen de acuerdo con una pdf para la cual se aplica el teorema del límite central (CLT), entonces $\hat{\theta}$ es un estimador consistente, puesto que la anchura de la pdf tiende a:

$$N\left(x; \mu, \frac{\sigma^2}{n}\right) \quad \longrightarrow \quad \frac{\sigma^2}{n} \rightarrow 0$$

$n \rightarrow \infty$

2.- Propiedades de los estimadores

Varianza

Experimentos repetidos dan lugar a valores diferentes del estimador distribuidos con una determinada varianza bien alrededor del valor verdadero, o de un valor erróneo si el estimador es sesgado.

Un estimador se dice que es eficiente si tiene la varianza más pequeña posible.

Ejemplo Varianza de la media muestral

$$V[\bar{x}] = V\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n^2} \sum_{i=1}^n V[x_i] = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n} \quad \longrightarrow \quad V[\bar{x}] = \frac{\sigma^2}{n}$$

Ejemplo Varianza de la varianza muestral

$$V[s^2] = V\left[\frac{\sigma^2}{n-1} \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2}\right] = \left[\frac{\sigma^2}{n-1}\right]^2 V\left[\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2}\right] = \left[\frac{\sigma^2}{n-1}\right]^2 V\left[\sum_{i=1}^n z_i^2\right] = \left[\frac{\sigma^2}{n-1}\right]^2 2(n-1) = \frac{2(\sigma^2)^2}{n-1} \quad \longrightarrow \quad V[s^2] = \frac{2(\sigma^2)^2}{n-1}$$

$V\left[\sum_{i=1}^n z_i^2\right] = V[\chi^2(n-1)] = 2(n-1)$

Si no conocemos σ^2

$$\hat{V}[\bar{x}] = \frac{s^2}{n} \quad \longrightarrow \quad \hat{\mu} = \bar{x} \pm \sqrt{V[\bar{x}]} = \bar{x} \pm \frac{s}{\sqrt{n}}$$

$$\hat{V}[s^2] = \frac{2(s^2)^2}{n-1} \quad \longrightarrow \quad \hat{\sigma}^2 = s^2 \pm \sqrt{V[s^2]} = s^2 \pm \sqrt{\frac{2}{n-1}} s^2$$

3.- Información y “likelihood”

Likelihood

Supongamos una variable aleatoria X con pdf $f(x; \theta)$.

Sea Ω_θ el espacio muestral o conjunto de posibles valores de X (puede depender de θ)

Tanto X como θ pueden ser un conjunto de valores \bar{X} , $\bar{\theta}$ no necesariamente de la misma dimensión

Consideremos un conjunto de n observaciones independientes x_i . Puesto que las variables son independientes, la pdf conjunta viene dada por:

$$L(\bar{x}; \bar{\theta}) = L(x_1, x_2, \dots, x_n; \bar{\theta}) = \prod_{i=1}^n f(x_i; \bar{\theta})$$

Función de verosimilitud o
likelihood

Función que depende tanto de las medidas x_i como de los parámetros $\bar{\theta}$

Una vez realizadas las medidas, estas son fijas y la función solo depende de los parámetros.

También se define su logaritmo como:

$$\ell \equiv \ln L(x_1, x_2, \dots, x_n; \bar{\theta}) = \ln \left(\prod_{i=1}^n f(x_i; \bar{\theta}) \right) = \sum_{i=1}^n \ln f(x_i; \bar{\theta})$$

3.- Información y “likelihood”

Información

Se define la información (de R. A. Fischer) dada sobre un parámetro θ por la observación de la variable aleatoria \bar{x} :

$$I_{\bar{x}}(\theta) = E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = E \left[\left(\frac{\partial \ell}{\partial \theta} \right)^2 \right] = \int_{\Omega_{\theta}} \left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 L(\bar{x}; \theta) d\bar{x}$$

$$I_{\bar{x}}(\theta) = E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = E \left[\left(\frac{\partial \ln \prod f(x_i; \theta)}{\partial \theta} \right)^2 \right] = E \left[\left(\frac{\partial}{\partial \theta} \sum \ln f(x_i; \theta) \right)^2 \right] = E \left[\left(\sum \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right)^2 \right]$$

Supongamos que:

1.- Ω_{θ} es independiente de $\bar{\theta}$

2.- $L(\bar{x}; \bar{\theta})$ es suficientemente regular para poder intercambiar el orden entre derivadas e integrales

$$E \left[\left(\frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right) \right] = \int \left[\frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right] f(x_i; \theta) dx_i = \int \frac{1}{f(x_i; \theta)} \left[\frac{\partial f(x_i; \theta)}{\partial \theta} \right] f(x_i; \theta) dx_i = \int \frac{\partial f(x_i; \theta)}{\partial \theta} dx_i = \frac{\partial}{\partial \theta} \int f(x_i; \theta) dx_i = \frac{\partial}{\partial \theta} 1 = 0$$

$$E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right) \right] = E \left[\left(\frac{\partial \ln \prod f(x_i; \theta)}{\partial \theta} \right) \right] = E \left[\left(\frac{\partial}{\partial \theta} \sum \ln f(x_i; \theta) \right) \right] = E \left[\left(\sum \frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right) \right] = \sum E \left[\frac{\partial \ln f(x_i; \theta)}{\partial \theta} \right] = 0$$

El valor esperado de la derivada del logaritmo de la likelihood es nulo

$$E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right) \right] = 0$$



4.- Límite de mínima varianza

Se puede demostrar que existe un límite inferior para la varianza de un estimador bajo ciertas condiciones generales:

Desigualdad de Rao-Cramér

Supongamos que tenemos un estimador $\hat{\theta}$ del parámetro θ con un sesgo dado por, $b_n(\hat{\theta}) = E[\hat{\theta}] - \theta$ varianza finita $V[\hat{\theta}]$ y que el rango de X no depende de θ . Entonces:

$$\begin{aligned} E\left[\hat{\theta} \frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] &= \int \cdots \int \hat{\theta} \left[\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta) \right] L(\bar{x}; \theta) dx_1 dx_2 \cdots dx_n = \\ &= \int \cdots \int \hat{\theta} \left[\frac{1}{L(\bar{x}; \theta)} \frac{\partial}{\partial \theta} L(\bar{x}; \theta) \right] L(\bar{x}; \theta) dx_1 dx_2 \cdots dx_n = \\ &= \int \cdots \int \hat{\theta} \left[\frac{\partial}{\partial \theta} L(\bar{x}; \theta) \right] dx_1 dx_2 \cdots dx_n = \int \cdots \int \hat{\theta} \frac{\partial}{\partial \theta} L(\bar{x}; \theta) dx_1 dx_2 \cdots dx_n = \\ &= \int \cdots \int \frac{\partial}{\partial \theta} [\hat{\theta} L(\bar{x}; \theta)] dx_1 dx_2 \cdots dx_n = \frac{\partial}{\partial \theta} \int \cdots \int \hat{\theta} L(\bar{x}; \theta) dx_1 dx_2 \cdots dx_n = \\ &= \frac{\partial}{\partial \theta} E[\hat{\theta}] = \frac{\partial}{\partial \theta} (\theta + b_n(\hat{\theta})) = 1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta}) \end{aligned}$$

$$b_n(\hat{\theta}) = E[\hat{\theta}] - \theta$$

4.- Límite de mínima varianza

El resultado anterior se puede expresar como: $E\left[\hat{\theta} \frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] = 1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta})$

Recordemos además que: $I_{\bar{x}}(\theta) = E\left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta}\right)^2\right]$ y que: $E\left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta}\right)\right] = 0$

Y por tanto: $V\left[\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] = E\left[\left(\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right)^2\right] - \left(E\left[\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right]\right)^2 = E\left[\left(\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right)^2\right] = I_{\bar{x}}(\theta)$

Tanto $\hat{\theta}$ como $\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)$ son variables aleatorias y podemos hablar de su covarianza

$$\text{cov}\left[\hat{\theta}(\bar{x}), \frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] = E\left[\hat{\theta}(\bar{x}) \frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] - E\left[\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] E[\hat{\theta}(\bar{x})] = 1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta})$$

El coeficiente de correlación vendrá dado por:

$$\rho^2 = \frac{\text{cov}\left[\hat{\theta}(\bar{x}), \frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right]^2}{V\left[\frac{\partial}{\partial \theta} \ln L(\bar{x}; \theta)\right] V[\hat{\theta}]} = \frac{\left(1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta})\right)^2}{I_{\bar{x}}(\theta) V[\hat{\theta}]} \leq 1$$

Desigualdad de Rao-Cramér

$$\sigma^2(\hat{\theta}) = V[\hat{\theta}] \geq \frac{\left(1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta})\right)^2}{I_{\bar{x}}(\theta)}$$

Para un conjunto de datos dado y una cierta cantidad de información $I(\theta)$ sobre un parámetro θ nunca podemos encontrar un estimador con una varianza más baja que el límite de Rao-Cramér

4.- Límite de mínima varianza

La información se puede expresar también como:

$$I_{\bar{x}}(\theta) = E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln L(\bar{x}; \theta)}{\partial \theta^2} \right]$$

Demostración

$$E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = E \left[\left(\frac{\partial \ln \prod_{i=1}^n f(x_i; \theta)}{\partial \theta} \right)^2 \right] = E \left[\left(\frac{\partial}{\partial \theta} \sum_{i=1}^n \ln f(x_i; \theta) \right)^2 \right] = E \left[\left(\sum_{i=1}^n \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right)^2 \right] = E \left[\sum_{i=1}^n \left(\frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right)^2 \right] + E \left[\sum_{i \neq j} \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \frac{\partial}{\partial \theta} \ln f(x_j; \theta) \right]$$

Donde el segundo término se anula por: $E \left[\left(\frac{\partial \ln f}{\partial \theta} \right) \right] = \int \left[\frac{\partial \ln f}{\partial \theta} \right] f dx_i = \int \frac{1}{f} \left[\frac{\partial f}{\partial \theta} \right] f dx_i = \int \frac{\partial f}{\partial \theta} dx_i = \frac{\partial}{\partial \theta} \int f dx_i = \frac{\partial}{\partial \theta} 1 = 0$

$$E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = E \left[\sum_{i=1}^n \left(\frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right)^2 \right] = \sum_{i=1}^n E \left[\left(\frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right)^2 \right] = \sum_{i=1}^n E \left[\left(\frac{f'(x_i; \theta)}{f(x_i; \theta)} \right)^2 \right] = \text{Orange Arrow}$$

$$E \left[\left(\frac{f'}{f} \right) \right] = \int_{\Omega} \frac{f'}{f} f dx = \int_{\Omega} f' dx = \frac{\partial}{\partial \theta} \int_{\Omega} f dx = \frac{\partial 1}{\partial \theta} = 0$$

Derivando de nuevo:

$$\frac{\partial}{\partial \theta} \int_{\Omega} \left(\frac{f'}{f} \right) f dx = \int_{\Omega} \left[\left(\frac{f'}{f} \right)' f + \left(\frac{f'}{f} \right) f' \right] dx = \int_{\Omega} \left[\left(\frac{f'}{f} \right)' + \left(\frac{f'}{f} \right)^2 \right] f dx = E \left[\left(\frac{f'}{f} \right)' \right] + E \left[\left(\frac{f'}{f} \right)^2 \right] = 0 \quad \text{Orange Arrow} \quad E \left[\left(\frac{f'}{f} \right)^2 \right] = -E \left[\left(\frac{f'}{f} \right)' \right]$$

$$= \sum_{i=1}^n E \left[\left(\frac{f'(x_i; \theta)}{f(x_i; \theta)} \right)^2 \right] = - \sum_{i=1}^n E \left[\left(\frac{f'(x_i; \theta)}{f(x_i; \theta)} \right)' \right] = -E \left[\sum_{i=1}^n \frac{\partial}{\partial \theta} \left(\frac{f'(x_i; \theta)}{f(x_i; \theta)} \right) \right] = -E \left[\sum_{i=1}^n \frac{\partial}{\partial \theta} \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \right] =$$



$$= -E \left[\sum_{i=1}^n \frac{\partial^2}{\partial \theta^2} \ln f(x_i; \theta) \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \sum_{i=1}^n \ln f(x_i; \theta) \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \sum_{i=1}^n \ln f(x_i; \theta) \right] = -E \left[\frac{\partial^2 \ln L(\bar{x}; \theta)}{\partial \theta^2} \right]$$

5.- Eficiencia de un estimador

Desigualdad de Rao-Cramér

$$I_{\bar{x}}(\theta) = E \left[\left(\frac{\partial \ln L(\bar{x}; \theta)}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln L(\bar{x}; \theta)}{\partial \theta^2} \right]$$

El resultado anterior se puede expresar como:

$$\sigma^2(\hat{\theta}) = V[\hat{\theta}] \geq \frac{\left(1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta}) \right)^2}{I_{\bar{x}}(\theta)}$$

$$\sigma^2(\hat{\theta}) \geq \frac{\left[1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta}) \right]^2}{E \left[\left(\frac{\partial \ln L}{\partial \theta} \right)^2 \right]} = \frac{\left(1 + \frac{\partial}{\partial \theta} b_n(\hat{\theta}) \right)^2}{-E \left[\frac{\partial^2 \ln L}{\partial \theta^2} \right]}$$

Existe por tanto un límite inferior en la varianza **MVB (minimum variance bound)** del estimador que:

- Disminuye con la información $I_{\bar{x}}(\theta)$
- Aumenta con el sesgo si depende de θ y si es *unbiased*

$$\sigma^2(\hat{\theta}) \geq \frac{1}{-E \left[\frac{\partial^2 \ln L}{\partial \theta^2} \right]}$$

Eficiencia

La eficiencia de un estimador se define por comparación con su **MVB** :

$$\varepsilon(\hat{\theta}) = \frac{\sigma_{\min}^2(\hat{\theta})}{\sigma^2(\hat{\theta})} \leq 1$$

Se dice que un estimador es eficiente si su varianza es igual a la mínima, es decir si su eficiencia es:

$$\varepsilon(\hat{\theta}) = 1$$

6.- Ejemplo estimador eficiente

Ejemplo

Distribución exponencial



$$f(x, \mu) = \frac{1}{\mu} e^{-x/\mu}$$

Consideremos n medidas independientes de una distribución exponencial, queremos estimar el valor de μ .

$$\ln L(\bar{x}; \mu) = \ln \prod_{i=1}^n f(x_i; \mu) = \sum_{i=1}^n \ln f(x_i; \mu) = \sum_{i=1}^n -\ln \mu - \frac{x_i}{\mu}$$

$$\frac{\partial \ln L(\bar{x}; \mu)}{\partial \mu} = \frac{\partial}{\partial \mu} \sum_{i=1}^n \left(-\ln \mu - \frac{x_i}{\mu} \right) = \sum_{i=1}^n \left(-\frac{1}{\mu} + \frac{x_i}{\mu^2} \right) \rightarrow \frac{\partial^2 \ln L(\bar{x}; \theta)}{\partial \mu^2} = \frac{\partial}{\partial \mu} \sum_{i=1}^n \left(-\frac{1}{\mu} + \frac{x_i}{\mu^2} \right) = \sum_{i=1}^n \left(\frac{1}{\mu^2} - \frac{2x_i}{\mu^3} \right)$$

$$I(\mu) = -E \left[\frac{\partial^2 \ln L(\bar{x}; \theta)}{\partial \theta^2} \right] = -E \left[\sum_{i=1}^n \left(\frac{1}{\mu^2} - \frac{2x_i}{\mu^3} \right) \right] = -\sum_{i=1}^n \left(\frac{1}{\mu^2} - \frac{2}{\mu^2} \right) = \frac{n}{\mu^2}$$

Si $\hat{\mu}$ es un estimador sin sesgo su varianza mínima es:



$$\sigma_{\min}^2 = \frac{\mu^2}{n}$$

Si utilizamos como estimador la media de la muestra: $\hat{\mu} = \bar{x}$ su varianza coincide con la varianza mínima, luego la media de la muestra es un estimador eficiente

$$V(\bar{x}) = \frac{1}{n} V(x) = \frac{1}{n} (E[x^2] - \mu^2) = \frac{2\mu^2}{n} - \frac{\mu^2}{n} = \frac{\mu^2}{n}$$