


Tema 9 Método de mínimos cuadrados

1. Principio de mínimos cuadrados.
2. Conexión con el método ML
3. Modelos lineales en los parámetros
4. Formulación a partir de derivadas
5. Ejemplo. Ajuste a una línea recta
6. Modelos no lineales en los parámetros.
7. Bondad de los ajustes
8. Residuos y “Pulls”
9. Mínimos cuadrados con datos clasificados.
10. Resumen Propiedades.



1. Principio de mínimos cuadrados

Supongamos n medidas independientes y_1, y_2, \dots, y_n consideradas variables aleatorias y asociadas a n puntos observacionales x_1, x_2, \dots, x_n considerados fijos.

Los valores verdaderos de los observables $\mu_1, \mu_2, \dots, \mu_n$ son desconocidos pero suponemos que pueden predecirse por un modelo teórico que lo predice para cada valor de x_i :

$$\mu_i = f(x_i, \theta_1, \theta_2, \dots, \theta_k) = f(x_i, \bar{\theta})$$

Función Hipótesis o modelo

Donde $\theta_1, \theta_2, \dots, \theta_m$ con $m < n$ es un conjunto de parámetros desconocidos. De acuerdo con el **Principio de Mínimos Cuadrados (LS)** los mejores valores de los parámetros desconocidos son los que minimizan la cantidad:

$$\chi^2 = \sum_{i=1}^n w_i (y_i - f_i)^2 = \text{minimun}$$

Los parámetros que minimizan la función de χ^2 , se denominan estimadores **LS** (*Least Squares*): $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$

- Los valores de los pesos w_i tienen en cuenta la precisión de las medidas: σ_i^2
- Bajo determinadas condiciones, el mínimo de la función encontrada χ^2 sigue una distribución de χ^2

1. Principio de mínimos cuadrados

- Si todas las medidas tienen la misma precisión o error

Mínimos cuadrados sin peso
(Unweighted LS)



$$\chi^2 = \sum_{i=1}^n (y_i - f_i)^2$$

- Si los errores son diferentes pero conocidos: $w_i = \frac{1}{\sigma_i^2}$

Mínimos cuadrados con peso
(Weighted LS)



$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - f_i}{\sigma_i} \right)^2$$

- Si las variables observadas son de Poisson: $\sigma_i^2 \approx f_i$



$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - f_i}{\sqrt{f_i}} \right)^2$$

- Si f es una función complicada se suele utilizar la aproximación:

Mínimos cuadrados simplificado
(Simplified LS)

$$\sigma_i^2 = y_i = n_i$$



$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - f_i}{\sqrt{y_i}} \right)^2$$

- Si las variables están correlacionadas:

$$V$$



$$\chi^2 = \sum_{i,j=1}^n (y_i - f_i) V_{ij}^{-1} (y_j - f_j)$$

- Asumimos que las variables x_i son valores precisos sin error o despreciable frente al error de y_i
- El método no impone ningún tipo de distribución a las variables (*distribution-free*)
- Si las variables son gaussianas:
 - El mínimo χ_{\min}^2 se distribuye como una distribución de chi-cuadrado.
 - Posibilidad de realizar un test del ajuste.

2. Conexión con el Método ML

Supongamos que las n medidas y_1, y_2, \dots, y_n se distribuyen gaussianamente alrededor de sus valores verdaderos aunque desconocidos μ_i y con varianza σ_i^2 conocida:

La pdf conjunta vendrá dada por:

$$g(y_1, y_2, \dots, y_n, \mu_1, \mu_2, \dots, \mu_n, \sigma_1^2, \sigma_2^2, \dots, \sigma_n^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{1}{2} \frac{(y_i - \mu_i)^2}{\sigma_i^2}\right]$$


con $\mu_i = f(x_i, \theta_1, \theta_2, \dots, \theta_m) = f(x_i, \bar{\theta})$

Tomando el logaritmo de la función pdf:

$$\ln L(\bar{\theta}) = \ln \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{(y_i - f(x_i, \bar{\theta}))^2}{2\sigma_i^2}\right] = -\frac{n}{2} \ln 2\pi - \sum_{i=1}^n \ln \sigma_i - \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{2\sigma_i^2}$$

Eliminando los términos aditivos que no dependen de $\bar{\theta}$

$$\ln L(\bar{\theta}) = -\frac{1}{2} \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2} = -\frac{1}{2} \chi^2 \quad \longrightarrow \quad \ln L(\bar{\theta}) = -\frac{1}{2} \chi^2 \quad \text{Relación entre ML y LS}$$



Maximizar $\ln L(\bar{\theta})$ equivale a minimizar la función:

$$\chi^2(\bar{\theta}) = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2}$$


2. Conexión con el Método ML

Ejemplo: Ajuste a una línea recta

$$\chi^2(\bar{\theta}) = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2}$$

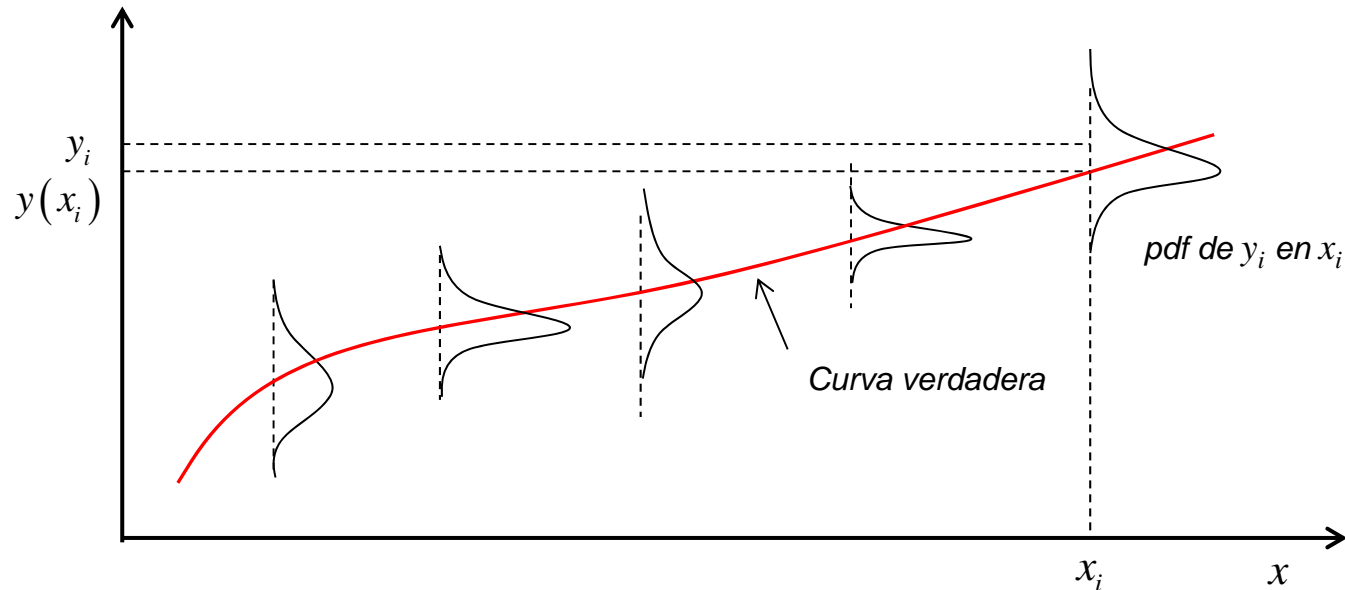
Residuos = desviaciones de las observaciones respecto a los “valores calculados”

$$y_i - f(x_i, \hat{\theta})$$



3. Modelo lineal en los parámetros

Las desviaciones de las medidas respecto a la curva verdadera se deben a errores en las medidas, pero conocemos las distribuciones, no necesariamente gaussianas, que siguen las medidas, y por tanto conocemos sus varianzas σ_i^2



Supongamos que la función modelo es **lineal en los parámetros**:

$$y = f(x, \bar{\theta}) = \sum_{j=1}^m a_j(x) \theta_j$$

Las funciones $a_j(x)$:

- Son funciones conocidas de la variable x , no necesariamente lineales en x
- Linealmente independientes entre ellas.

3. Modelo lineal en los parámetros

Los valores de la función en cada punto x_i vendrán dados por:

$$f(x_i; \bar{\theta}) = \sum_{j=1}^m a_j(x_i) \theta_j = \sum_{j=1}^m A_{ij} \theta_j \quad \text{con} \quad A_{ij} = a_j(x_i)$$

Y la expresión de χ^2 \longrightarrow
$$\chi^2 = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2} = \sum_{i=1}^n \frac{1}{\sigma_i^2} \left(y_i - \sum_{j=1}^m A_{ij} \theta_j \right)^2$$

Derivando respecto a cada parámetro θ_k e igualando a cero:

$$\frac{\partial \chi^2}{\partial \theta_k} = \frac{\partial}{\partial \theta_k} \sum_{i=1}^n \frac{1}{\sigma_i^2} \left(y_i - \sum_{j=1}^m A_{ij} \theta_j \right)^2 = \sum_{i=1}^n -\frac{2}{\sigma_i^2} \left(y_i - \sum_{j=1}^m A_{ij} \theta_j \right) A_{ik} = 0 \quad k = 1, 2, \dots, m$$

**Ecuaciones
normales**

$$\sum_{j=1}^m \left(\sum_{i=1}^n \frac{A_{ik} A_{ij}}{\sigma_i^2} \right) \theta_j = \sum_{i=1}^n \frac{A_{ik} y_i}{\sigma_i^2} \quad k = 1, 2, \dots, m$$

Sistema de m ecuaciones con m incógnitas

3. Modelo lineal en los parámetros

Ecuaciones normales

$$\sum_{j=1}^m \left(\sum_{i=1}^n \frac{A_{ik} A_{ij}}{\sigma_i^2} \right) \theta_j = \sum_{i=1}^n \frac{A_{ik} y_i}{\sigma_i^2} \quad k = 1, 2, \dots, m$$

Sistema lineal de ecuaciones inhomogéneo de m incógnitas, solución exacta y única

En notación matricial:

El modelo lineal se puede expresar como:

$$f(x_i; \bar{\theta}) = \sum_{j=1}^m a_j(x_i) \theta_j = \sum_{j=1}^m A_{ij} \theta_j$$

$$\begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{pmatrix} = \begin{pmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ A_{21} & A_{22} & \cdots & A_{2m} \\ \vdots & \vdots & & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nm} \end{pmatrix} \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{pmatrix}$$



$$\bar{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{pmatrix} \quad A = \begin{pmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ A_{21} & A_{22} & \cdots & A_{2m} \\ \vdots & \vdots & & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nm} \end{pmatrix}$$

$$\bar{f} = A \bar{\theta}$$

$$\left. \begin{aligned} \sum_{i=1}^n \frac{A_{i1} A_{i1}}{\sigma_i^2} \theta_1 + \sum_{i=1}^n \frac{A_{i1} A_{i2}}{\sigma_i^2} \theta_2 + \cdots + \sum_{i=1}^n \frac{A_{i1} A_{im}}{\sigma_i^2} \theta_m &= \sum_{i=1}^n \frac{A_{i1} y_i}{\sigma_i^2} \\ \sum_{i=1}^n \frac{A_{i2} A_{i1}}{\sigma_i^2} \theta_1 + \sum_{i=1}^n \frac{A_{i2} A_{i2}}{\sigma_i^2} \theta_2 + \cdots + \sum_{i=1}^n \frac{A_{i2} A_{im}}{\sigma_i^2} \theta_m &= \sum_{i=1}^n \frac{A_{i2} y_i}{\sigma_i^2} \\ \vdots & \\ \sum_{i=1}^n \frac{A_{im} A_{i1}}{\sigma_i^2} \theta_1 + \sum_{i=1}^n \frac{A_{im} A_{i2}}{\sigma_i^2} \theta_2 + \cdots + \sum_{i=1}^n \frac{A_{im} A_{im}}{\sigma_i^2} \theta_m &= \sum_{i=1}^n \frac{A_{im} y_i}{\sigma_i^2} \end{aligned} \right\}$$

3. Modelo lineal en los parámetros

Ecuaciones normales

Y la cantidad a minimizar:

$$\chi^2 = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2} = \sum_{i,j=1}^n (y_i - f(x_i, \bar{\theta})) V_{ij}^{-1} (y_j - f(x_j, \bar{\theta}))$$

$$\bar{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad V = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{pmatrix}$$

$$\chi^2 = (\bar{y} - A\bar{\theta})^T V^{-1} (\bar{y} - A\bar{\theta})$$

Derivando e igualando a cero:

$$\nabla \chi^2 = -2(A^T V^{-1} \bar{y} - A^T V^{-1} A \bar{\theta}) = 0 \quad \longrightarrow \quad (A^T V^{-1} A) \bar{\theta} = A^T V^{-1} \bar{y}$$

Y siempre que la matriz $(A^T V^{-1} A)$ no sea singular

$$\hat{\bar{\theta}} = (A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y}$$

Válida para variables no independientes
introduciendo la matriz de covarianzas

3. Modelo lineal en los parámetros

Valor esperado

$$\hat{\theta} = (A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y}$$

$$E[\hat{\theta}] = E\left[(A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y}\right] = (A^T V^{-1} A)^{-1} A^T V^{-1} E[\bar{y}] = (A^T V^{-1} A)^{-1} A^T V^{-1} A \bar{\theta} = \bar{\theta}$$

$$\begin{aligned}\bar{y} &= y + \bar{y} - y = A\theta + \bar{y} - y = A\theta + \bar{\varepsilon} \\ E[\bar{y}] &= E[A\bar{\theta} + \bar{\varepsilon}] = A\bar{\theta} + E[\bar{\varepsilon}] = A\bar{\theta}\end{aligned}$$

Los estimadores **LS** resultan ser estimadores sin sesgo, suponiendo que el modelo sea el correcto

Varianza

En nuestro caso:

$$\begin{aligned}\hat{\theta} &= (A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y} \quad \longrightarrow \quad V(\hat{\theta}) = S V(\bar{y}) S^T \\ S_{ij} &= \frac{\partial \theta_i}{\partial y_j} = \left[(A^T V^{-1} A)^{-1} A^T V^{-1} \right]_{ij} \quad S = \left[(A^T V^{-1} A)^{-1} A^T V^{-1} \right]\end{aligned}$$

Propagación de errores:

$$\begin{aligned}V(\bar{y}) &= S V(\bar{x}) S^T \\ V_{kl}(\bar{y}) &= \sum_{i=1}^n \sum_{j=1}^n \frac{\partial y_k}{\partial x_i} \left| \frac{\partial y_l}{\partial x_j} \right| V_{ij}(x) \\ S_{ij} &= \frac{\partial y_i}{\partial x_j}\end{aligned}$$

$$V(\hat{\theta}) = S V(\bar{y}) S^T = (A^T V^{-1} A)^{-1} A^T V^{-1} V V^{-1} A (A^T V^{-1} A)^{-1} = (A^T V^{-1} A)^{-1}$$

Teorema de Markov-Gauss.- “Bajo ciertas condiciones, de todos los estimadores lineales y unbiased, los estimadores LS tienen la varianza mínima posible”

$$V(\hat{\theta}) = (A^T V^{-1} A)^{-1}$$

4. Formulación a partir de derivadas

Los resultados anteriores se pueden obtener también a partir de las derivadas de la función χ^2

$$\chi^2 = (\bar{y} - A\bar{\theta})^T V^{-1} (\bar{y} - A\bar{\theta})$$

$$V(\hat{\bar{\theta}}) = (A^T V^{-1} A)^{-1}$$

$$\left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\hat{\bar{\theta}}} = -2A^T V^{-1} (\bar{y} - A\bar{\theta}) \quad \longrightarrow \quad \left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\hat{\bar{\theta}}} = 2A^T V^{-1} A = 2V^{-1}(\hat{\bar{\theta}})$$

Podemos calcular la matriz de covarianza mediante las derivadas sin necesidad de usar las matrices A y V

$$V^{-1}(\hat{\bar{\theta}}) = \frac{1}{2} \left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\hat{\bar{\theta}}}$$

Incluso la solución se puede expresar en términos de las derivadas:

Como no conocemos la solución de los parámetros calculamos las derivadas en un punto aproximado $\bar{\theta} = \bar{\theta}^0$

$$\begin{aligned} \hat{\bar{\theta}} &= (A^T V^{-1} A)^{-1} A^T V^{-1} \bar{y} = 2 \left(\left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}^0} \right)^{-1} A^T V^{-1} \bar{y} = \left(\left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}^0} \right)^{-1} \left[\left(\left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}^0} \right) \bar{\theta}^0 - \left(\left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\bar{\theta}^0} \right) \right] = \\ &= \bar{\theta}^0 - \left(\left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}^0} \right)^{-1} \left(\left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\bar{\theta}^0} \right) \end{aligned}$$

Método de **Newton-Raphson** para ecuaciones lineales.
Exacto para el caso lineal

5. Ejemplo. Ajuste a una línea recta

El caso más sencillo de dependencia lineal en los parámetros es la línea recta

$$y = f(x; \bar{\theta}) = \sum_{i=1}^m a_i(x) \theta_i = a_1(x) \theta_1 + a_2(x) \theta_2 = a + bx$$

Es decir:

$$\theta_1 = a ; \theta_2 = b$$

$$a_1(x) = 1 ; a_2(x) = x$$

En notación matricial:

$$\bar{\theta} = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} a \\ b \end{pmatrix} \quad A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{21} \\ \vdots & \vdots \\ A_{n1} & A_{21} \end{pmatrix} \xrightarrow{\text{red arrow}} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \quad \Rightarrow \quad \bar{f} = A\bar{\theta} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix}$$

Si las medidas son independientes, la matriz de covarianzas es diagonal y es más sencillo $V_{ii}(y) = \sigma_i^2$

$$\chi^2 = \sum_{i=1}^n \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2 \quad \Rightarrow \quad \left. \begin{aligned} \frac{\partial \chi^2}{\partial a} &= 0 \\ \frac{\partial \chi^2}{\partial b} &= 0 \end{aligned} \right\} \Rightarrow \left. \begin{aligned} -2 \sum_{i=1}^n \frac{y_i - a - bx_i}{\sigma_i^2} &= 0 \\ -2 \sum_{i=1}^n \frac{x_i (y_i - a - bx_i)}{\sigma_i^2} &= 0 \end{aligned} \right\}$$

Sistema de dos ecuaciones con dos incógnitas que se resuelve fácilmente

5. Ejemplo. Ajuste a una línea recta

Sistema de ecuaciones normales

$$\left\{ \begin{array}{l} \left(\sum_{i=1}^n \frac{1}{\sigma_i^2} \right) a + \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right) b = \sum_{i=1}^n \frac{y_i}{\sigma_i^2} \\ \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right) a + \left(\sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} \right) b = \sum_{i=1}^n \frac{x_i y_i}{\sigma_i^2} \end{array} \right.$$

$$\hat{a} = \frac{\left(\sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{y_i}{\sigma_i^2} \right) - \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{x_i y_i}{\sigma_i^2} \right)}{\left(\sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{1}{\sigma_i^2} \right) - \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right)^2}$$

$$\hat{b} = \frac{\left(\sum_{i=1}^n \frac{x_i y_i}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{1}{\sigma_i^2} \right) - \left(\sum_{i=1}^n \frac{y_i}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right)}{\left(\sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} \right) \left(\sum_{i=1}^n \frac{1}{\sigma_i^2} \right) - \left(\sum_{i=1}^n \frac{x_i}{\sigma_i^2} \right)^2}$$

La matriz de covarianza vendrá dada (suponiendo todos los errores iguales): $\sigma_i = \sigma$

$$V(\hat{\theta}) = (A^T V^{-1} A)^{-1} = (A^T A)^{-1} \sigma^2 = \sigma^2 \left[\begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \right]^{-1} = \sigma^2 \begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix}^{-1}$$

$$= \frac{\sigma^2}{n \sum x_i^2 - (\sum x_i)^2} \begin{pmatrix} \sum x_i^2 & -\sum x_i \\ -\sum x_i & n \end{pmatrix} = \frac{\sigma^2}{n(\overline{x^2} - \bar{x}^2)} \begin{pmatrix} \overline{x^2} & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix}$$

Si los errores no son iguales basta introducir los cambios:

$$\left\{ \begin{array}{l} \bar{x} \rightarrow \bar{x} = \frac{\sum x_i / \sigma_i^2}{\sum 1 / \sigma_i^2}; \quad \sigma^2 \rightarrow \overline{\sigma^2} = \frac{\sum \sigma_i^2 / \sigma_i^2}{\sum 1 / \sigma_i^2} = \frac{1}{\sum 1 / \sigma_i^2} \end{array} \right.$$

$$\begin{pmatrix} V(\hat{a}) & \text{cov}(\hat{a}, \hat{b}) \\ \text{cov}(\hat{a}, \hat{b}) & V(\hat{b}) \end{pmatrix} = \frac{\sigma^2}{n(\overline{x^2} - \bar{x}^2)} \begin{pmatrix} \overline{x^2} & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix}$$

5. Ejemplo. Ajuste a una línea recta

Valor de χ^2 en el mínimo
(NB: no dividido por el
los grados de libertad)

```
PARAMETER CORRELATION COEFFICIENTS
GLOBAL      1      2
0.91298     1.000 -0.913
0.91298    -0.913  1.000
```


```
EXTERNAL ERROR MATRIX.      NDIM= 2      NPAR= 2      ERR DEF=1
1.561e-001 -2.024e-002
-2.024e-002 3.147e-003
```

```
FCN=6.98702 FROM MIGRAD      STATUS=CONVERGED      31 CALLS      32 TOTAL
EDM=3.28338e-021      STRATEGY= 1      ERROR MATRIX ACCURATE
```

```
EXT PARAMETER      PARABOLIC      MINOS ERRORS
NO.  NAME
1  aa
2  bb
(Int_t)0
```

VALUE	ERROR
4.58428e+000	3.95139e-001
1.21304e+000	5.61001e-002

Valores de los parámetros y sus
errores aproximados según MINUIT



Status: 'CONVERGED' puede ser 'FAILED'
Estimated Distance to Minimum (EDM)
debe ser orden $O(10^{-6})$
Error Matrix Quality
Debe ser 'ACCURATE', pero puede ser
'APPROXIMATE' si hay problemas

5. Ejemplo. Ajuste a una línea recta

Matriz de correlación ρ_{ij}
(Calculada como)

$$\rho_{ij} = V_{ij} / \sigma_i \sigma_j$$

PARAMETER NO.	CORRELATION GLOBAL	1	2
1	0.91298	1.000	-0.913
2	0.91298	-0.913	1.000

EXTERNAL ERROR MATRIX. NDIM= 2 NPAR= 2 ERR DEF

1.561e-001 -2.024e-002
-2.024e-002 3.147e-003

FCN=6.98702 FROM MIGRAD STATUS=CONVERGED 31 CALL


EDM=3.28338e-021 STRATEGY= 1

EXT PARAMETER NO.	NAME	VALUE	PARABOLIC ERROR	MINUS NEGATIVE
1	aa	4.58428e+000	3.95139e-001	
2	bb	1.21304e+000	5.61001e-002	

(Int_t)0

Matriz de covarianza
(calculada como)

$$V_{ij} = \frac{1}{2} \left(\frac{\partial^2 \chi^2}{\partial \theta_i \partial \theta_j} \right)^{-1}$$



Errores simétricos
Symmetric errors calculados a
partir de 2nd derivada de $-\ln(L)$ or χ^2

6. Modelos no lineales en los parámetros

Si la dependencia de la función modelo $f(x)$ con los parámetros no es lineal no hay solución exacta.

Minimización mediante un proceso iterativo hasta alcanzar la mejor aproximación.

De acuerdo con el **Principio de Mínimos Cuadrados**, la mejor estimación de los parámetros viene dada por los valores que minimizan la cantidad:

$$\chi^2 = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2} \quad \longrightarrow \quad \chi^2 = (\bar{y} - \bar{f})^T V^{-1} (\bar{y} - \bar{f})$$

Partimos de una solución aproximada: $\bar{\theta}^0 = \{\theta_1^0, \theta_2^0, \dots, \theta_m^0\}$

Derivando respecto a los parámetros y evaluando en dicha solución aproximada:

$$g_k(\bar{\theta}^0) = \left. \frac{\partial \chi^2}{\partial \theta_k} \right|_{\bar{\theta}=\bar{\theta}^0} = \sum_{i=1}^n \left(-\frac{2}{\sigma_i^2} \right) (y_i - f_i(x_i; \bar{\theta}^0)) \left. \frac{\partial f_i}{\partial \theta_k} \right|_{\bar{\theta}=\bar{\theta}^0}$$

Si $\bar{\theta}^0$ fuera el mínimo se anularían, como no lo es, buscamos un incremento tal que:

$$\bar{g}(\bar{\theta}^0 + \Delta \bar{\theta}^0) = 0$$

Desarrollamos en serie de potencias y nos quedamos a primer orden:

$$g_k(\bar{\theta}^0 + \Delta \bar{\theta}^0) = g_k(\bar{\theta}^0) + \left. \frac{\partial g_k}{\partial \theta_1} \right|_{\bar{\theta}^0} \Delta \theta_1^0 + \left. \frac{\partial g_k}{\partial \theta_2} \right|_{\bar{\theta}^0} \Delta \theta_2^0 + \dots + \left. \frac{\partial g_k}{\partial \theta_m} \right|_{\bar{\theta}^0} \Delta \theta_m^0 = 0 \quad k = 1, 2, \dots, m$$

Sistema de m ecuaciones con m incógnitas que son los desplazamientos: $\Delta \theta_k^0$

6. Modelos no lineales en los parámetros

Los coeficientes del sistema de ecuaciones son las derivadas segundas de la función a minimizar

$$G_{lk} \equiv \frac{\partial g_k}{\partial \theta_l} = \frac{\partial^2 \chi^2}{\partial \theta_l \partial \theta_k} = \sum_{i=1}^n \left(-\frac{2}{\sigma_i^2} \right) \left[-\frac{\partial f_i}{\partial \theta_l} \frac{\partial f_i}{\partial \theta_k} + (y_i - f_i) \frac{\partial^2 f_i}{\partial \theta_l \partial \theta_k} \right]$$

Cuyos valores se calculan numérica o analíticamente y todas las cantidades se calculan en $\bar{\theta} = \bar{\theta}^0$

En notación vectorial, el sistema de ecuaciones se escribe como:

$$G \Delta \bar{\theta}^0 = -\bar{g}(\bar{\theta}^0) \quad \longrightarrow \quad \Delta \bar{\theta}^0 = -G^{-1}(\bar{\theta}^0) \bar{g}(\bar{\theta}^0)$$

La nueva solución $\bar{\theta}^1 = \bar{\theta}^0 + \Delta \bar{\theta}^0$ es el punto de partida de la siguiente iteración

En el caso lineal:

$$f(x_i; \bar{\theta}) = \sum_{j=1}^m a_j(x_i) \theta_j \quad \longrightarrow \quad \frac{\partial f}{\partial \theta_k} = a_k(x) \quad \longrightarrow \quad \frac{\partial^2 f}{\partial \theta_l \partial \theta_k} = 0$$

Se recuperan las ecuaciones normales:

6. Modelos no lineales en los parámetros

Desarrollando en serie de potencias en torno a $\bar{\theta}^0$

$$\chi^2(\bar{\theta}) = \chi^2(\bar{\theta}^0) + \left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\bar{\theta}^0} (\bar{\theta} - \bar{\theta}^0) + \frac{1}{2} (\bar{\theta} - \bar{\theta}^0)^T \left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}^0} (\bar{\theta} - \bar{\theta}^0) + \dots$$

En caso de dependencia lineal en los parámetros, los términos de tercer orden y superiores se anulan y la función resulta ser una parábola

Repitiendo el desarrollo pero en torno al mínimo $\bar{\theta}_m$ y despreciando los términos de orden 3 en adelante:

$$\chi^2(\bar{\theta}) = \chi^2(\bar{\theta}_m) + (\bar{\theta} - \bar{\theta}_m)^T \left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\bar{\theta}_m} + \frac{1}{2} (\bar{\theta} - \bar{\theta}_m)^T \left. \frac{\partial^2 \chi^2}{\partial \bar{\theta}^2} \right|_{\bar{\theta}=\bar{\theta}_m} (\bar{\theta} - \bar{\theta}_m)$$

Teniendo en cuenta que:

$$\left. \begin{aligned} \chi^2(\bar{\theta}_m) &= \chi^2_{\min} \\ \left. \frac{\partial \chi^2}{\partial \bar{\theta}} \right|_{\bar{\theta}=\bar{\theta}_m} &= 0 \\ (V^{-1})_{ij} &= \frac{1}{2} \left[\frac{\partial^2 \chi^2}{\partial \theta_i \partial \theta_j} \right]_{\bar{\theta}=\bar{\theta}_m} \end{aligned} \right\}$$



$$\chi^2(\bar{\theta}) = \chi^2_{\min} + (\bar{\theta} - \bar{\theta}_m)^T V^{-1}(\hat{\bar{\theta}}) (\bar{\theta} - \bar{\theta}_m)$$

Ecuación base para el cálculo de intervalos de confianza mediante el método **LS** (similar al método **ML**):



6. Modelos no lineales en los parámetros

$$\chi^2(\bar{\theta}) = \chi_{\min}^2 + (\bar{\theta} - \bar{\theta}_m)^T V^{-1}(\hat{\hat{\theta}})(\bar{\theta} - \bar{\theta}_m)$$

En caso de un solo parámetro:


$$\chi^2(\theta) = \chi_{\min}^2 + \frac{(\theta_m - \theta)^2}{\sigma^2}$$

$$\chi^2(\theta_m \pm \sigma) = \chi_{\min}^2 + 1$$

$$\chi^2(\theta_m \pm 2\sigma) = \chi_{\min}^2 + 4$$

\vdots \vdots

$$\chi^2(\theta_m \pm a\sigma) = \chi_{\min}^2 + a^2$$



El error en el parámetro viene dado por la variación de χ^2 en una unidad

7. Bondad de los ajustes

Si las n medidas y_1, y_2, \dots, y_n se distribuyen normalmente, el valor de χ^2 obtenido se puede utilizar como un test de la hipótesis modelo:

$$\left(\frac{y_i - f(x_i; \theta)}{\sigma_i} \right)$$



Representa una medida de la desviación entre la medida y_i y el modelo $f(x_i; \theta)$

χ^2 es una medida del acuerdo entre la hipótesis, **Teoría**, y los datos observados, **Experimento**.

Se puede demostrar que si:

1. Los valores de y_1, y_2, \dots, y_n son variables aleatorias distribuidas normalmente con varianzas conocidas σ_i^2 (o distribuidas multi-normalmente con matriz de covarianza V)
2. La hipótesis $f(x; \theta_1, \theta_2, \dots, \theta_m)$ es lineal en los parámetros θ_i
3. La hipótesis es correcta.



El mínimo de la función de χ^2 se distribuye de acuerdo a una distribución de $f(\chi^2; \nu)$ con $\nu = n - m$ grados de libertad

$$\chi^2(\bar{\theta}) = \sum_{i=1}^n \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2}$$

$$\chi^2(\bar{\theta}) = \sum_{i,j=1}^n (y_i - f(x_i, \bar{\theta}))(V^{-1})_{ij} (y_j - f(x_j, \bar{\theta}))$$

7. Bondad de los ajustes

Como el valor esperado de la distribución de $f(\chi^2; \nu)$ es el número de grados de libertad se suele utilizar la variable χ^2 dividida por el número de grados de libertad χ^2/ν como una medida de la bondad del ajuste:

$$E[\chi^2]/\nu = 1$$


Se pueden dar los siguientes casos:

1. Si $\chi^2/\nu \approx 1$, el resultado es el esperado. Todo es correcto.
2. Si $\chi^2/\nu \ll 1$, el ajuste es mejor de lo esperado para esos errores.


Probablemente los errores estén *sobre-estimados* o correlacionados.

1. Si $\chi^2/\nu \gg 1$, hay razones para dudar de que la hipótesis sea correcta.


- Medidas erróneas
- Errores subestimados
- Modelo teórico incorrecto
- Mala suerte




Errores sobre-estimados



Medidas erróneas



Errores sub-estimados



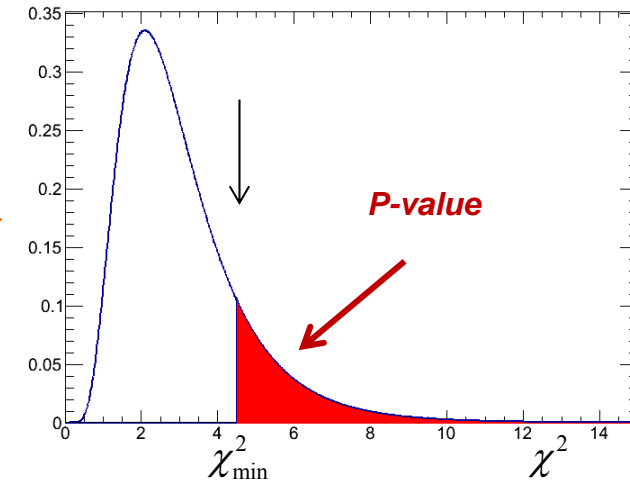
Modelo incorrecto

7. Bondad de los ajustes

Se utiliza también como medidor de la bondad del ajuste el **P-value**, o la probabilidad de que la hipótesis de lugar a un valor de χ^2_{\min} igual o mayor que el obtenido

$$P(\chi^2_{\min}) = \int_{\chi^2_{\min}}^{\infty} f(\chi^2, \nu) d\chi^2$$

ROOT function
TMath::Prob(chi2,ndf)



Integral acumulativa es uniforme $\longrightarrow P(\chi^2_{\min})$ Se distribuye uniformemente en [0,1]

Si el modelo y las fluctuaciones (errores) son correctas la distribución $\text{Prob}(\chi^2_{\min}, \text{ndf})$ debe ser plana:


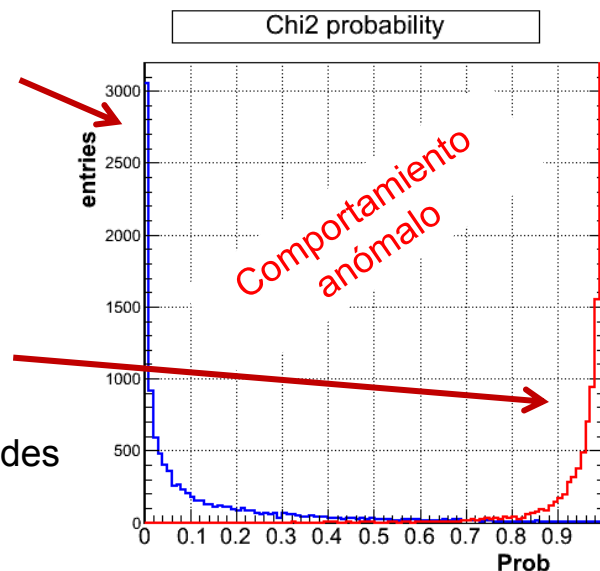
Desviaciones del comportamiento plano indican que algo va mal:

- Si $\chi^2/\nu \gg 1 \rightarrow P(\chi^2_{\min}) \downarrow$

- Sucesos de fondo
- Mal ajuste
- Errores muy pequeños

- Si $\chi^2/\nu \ll 1 \rightarrow P(\chi^2_{\min}) \uparrow$

- Errores demasiado grandes



7. Bondad de los ajustes

Como el valor esperado de χ^2 es igual al número de grados de libertad, el cociente se considera también una medida del acuerdo entre datos e hipótesis pero...

$$\chi^2 / n_d \approx 1$$

¡¡**cuidado!!**

No conviene fiarse solo de:

$$\chi^2 / n_d$$

Comprobar siempre el P-value

Ejemplo

$$\chi^2 = 15 ; n_d = 10$$

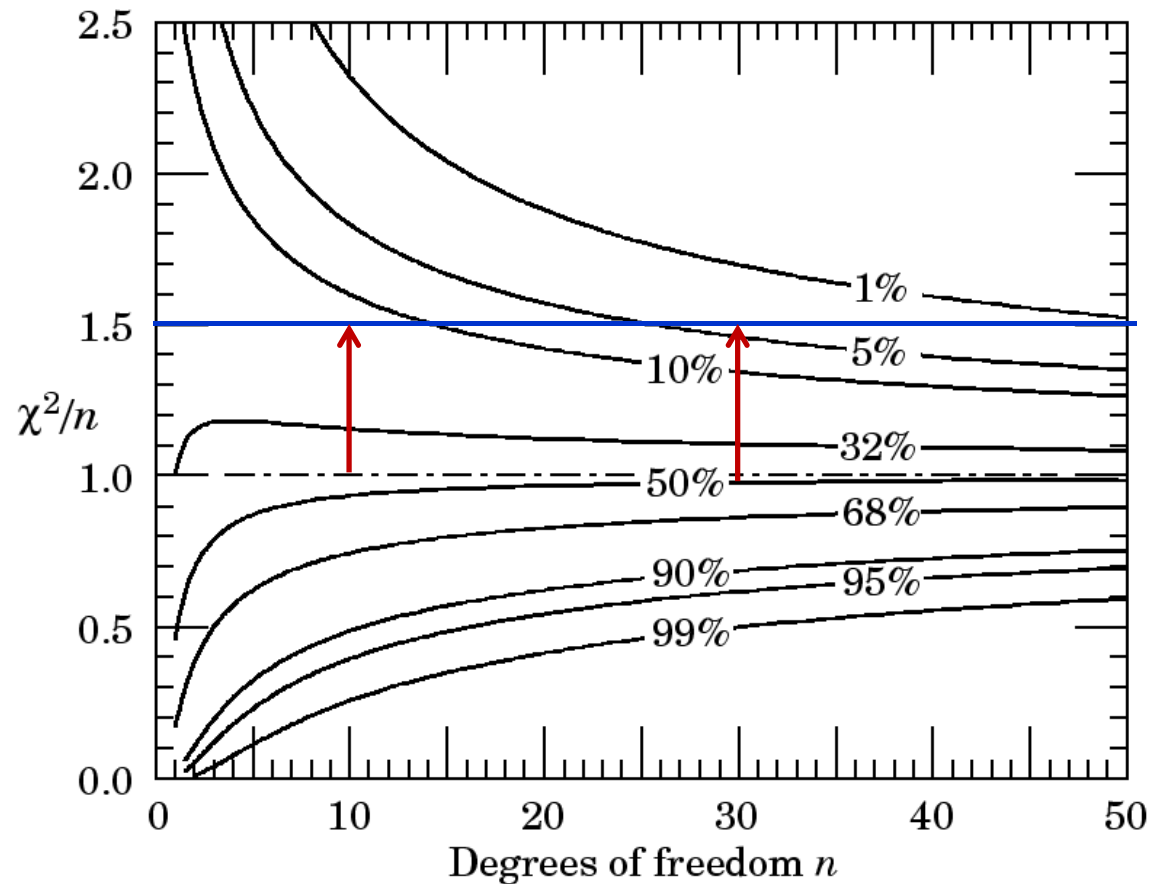
$$\rightarrow P = 0.13$$

Ajuste aceptable

$$\chi^2 = 45 ; n_d = 30$$

$$\rightarrow P = 0.04 !!$$

Ajuste empieza a ser cuestionable



8. Residuos y Pulls

Una forma sencilla de comprobar que el ajuste es bueno es mirar la distribución de residuos y pulls

Residuos se definen como las diferencias o desviaciones entre las medidas originales y los valores ajustados:



$$\varepsilon_i = y_i - \mu_i$$

Si las precisiones de los puntos son diferentes, mejor dividir por el error

Pulls (Stretch functions) se definen como los residuos divididos por la precisión



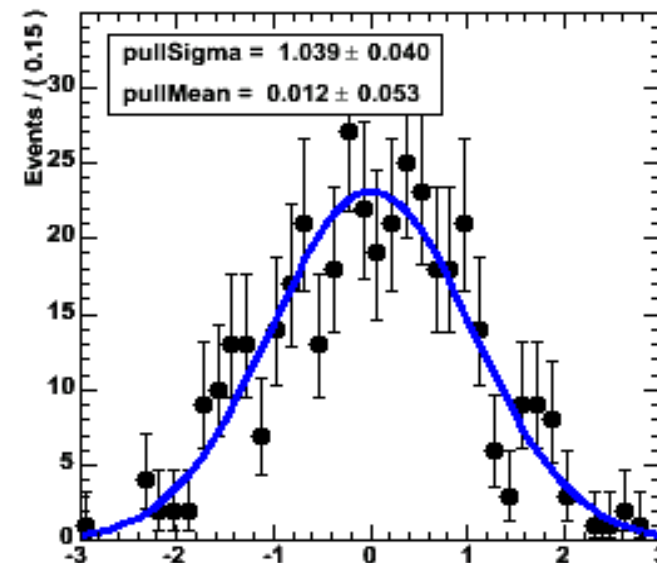
$$z_i = \frac{\varepsilon_i}{\sigma(\varepsilon_i)}$$

Si las medidas son independientes y el problema considerado es suficientemente lineal, el comportamiento esperado es el de una distribución normal estándar $N(0,1)$

Propiedades de los “pulls”

- El valor medio debe ser cero si no hay sesgo (*bias*)
- La anchura debe ser 1 si el error es correcto

Ejemplo sin sesgo y con error correcto dentro de la precisión estadística



9. Mínimos cuadrados con datos clasificados

En ocasiones la función modelo $f(x; \theta)$ es una distribución o pdf. Supongamos n observaciones de la variable aleatoria x a partir de las cuales construimos un histograma con N bins:

- Las medidas son ahora el contenido de los bins: $y_i = n_i \quad i = 1, 2, \dots, N$
- La función $f(x; \bar{\theta})$ una pdf hipotética para la cual queremos calcular sus parámetros: $\bar{\theta} = \{\theta_1, \theta_2, \dots, \theta_m\}$

El número de entradas predichas en cada *bin* vendrá dado por:

$$f_i(\bar{\theta}) = n \int_{x_i^{\min}}^{x_i^{\max}} f(x; \bar{\theta}) dx = np_i(\bar{\theta})$$

$p_i(\bar{\theta})$ Probabilidad de obtener una entrada en el bin i -ésimo
 x_i^{\min}, x_i^{\max} Límites de *bin* i -ésimo

Y los parámetros se obtienen minimizando la cantidad:

$$\chi^2(\bar{\theta}) = \sum_{i=1}^N \frac{(y_i - f(x_i, \bar{\theta}))^2}{\sigma_i^2} = \sum_{i=1}^N \frac{(n_i - np_i(\bar{\theta}))^2}{\sigma_i^2}$$

Donde:

- n_i son los contenidos observados de cada bin
- σ_i^2 son las varianzas del número de entradas de cada bin

Dos planteamientos equivalentes:

- Los valores observados se distribuyen multi-nomialmente ligados por: $\rightarrow \sum_{i=1}^N n_i = \sum_{i=1}^N np_i = n$
- Los valores observados se distribuyen según N variables de Poisson independientes

9. Mínimos cuadrados con datos clasificados

Valores distribuidos multi-nomialmente.

En este caso la matriz de covarianza viene dada por:

$$V = \begin{pmatrix} np_1(1-p_1) & -np_1p_2 & \cdots & -np_1p_N \\ -np_2p_1 & np_2(1-p_2) & \cdots & -np_2p_N \\ \vdots & \vdots & \ddots & \vdots \\ -np_Np_1 & -np_Np_2 & \cdots & np_N(1-p_N) \end{pmatrix}$$

Matriz singular debido a $\sum_{i=1}^N n_i = \sum_{i=1}^N np_i = n$

Método LS no es aplicable $|V| = 0$

Solución:

Eliminamos una fila y columna correspondiente a una de las clases (la última), para que la nueva matriz V^* no sea singular:

Se puede comprobar fácilmente que la matriz inversa de V^* es:



$$V^{*-1} = \frac{1}{n} \begin{pmatrix} p_1^{-1} + p_N^{-1} & p_N^{-1} & \cdots & p_N^{-1} \\ p_N^{-1} & p_2^{-1} + p_N^{-1} & \cdots & p_N^{-1} \\ \vdots & \vdots & \ddots & \vdots \\ p_N^{-1} & p_N^{-1} & \cdots & p_{N-1}^{-1} + p_N^{-1} \end{pmatrix}$$

Minimizamos entonces la cantidad:

$$\chi^2(\bar{\theta}) = (\bar{y} - n\bar{p})^T V^{*-1} (\bar{y} - n\bar{p}) = \sum_{i=1}^{N-1} \sum_{j=1}^{N-1} (n_i - np_i) V_{ij}^{*-1} (n_j - np_j)$$

9. Mínimos cuadrados con datos clasificados

Tras unas cuantas operaciones:

$$\begin{aligned}
 \chi^2(\bar{\theta}) &= \sum_{i=1}^{N-1} \sum_{j=1}^{N-1} (n_i - np_i) V_{ij}^{*-1} (n_j - np_j) = \frac{1}{n} \left\{ \sum_{i=1}^{N-1} \frac{(n_i - np_i)^2}{p_i} + \frac{1}{p_N} \sum_{i=1}^{N-1} \sum_{j=1}^{N-1} (n_i - np_i)(n_j - np_j) \right\} = \\
 &= \frac{1}{n} \left\{ \sum_{i=1}^{N-1} \frac{(n_i - np_i)^2}{p_i} + \frac{1}{p_N} \left[\sum_{i=1}^{N-1} (n_i - np_i) \right]^2 \right\} = \frac{1}{n} \left\{ \sum_{i=1}^{N-1} \frac{(n_i - np_i)^2}{p_i} + \frac{1}{p_N} [(n - n_N) - (n - np_N)]^2 \right\} = \\
 &= \frac{1}{n} \left\{ \sum_{i=1}^{N-1} \frac{(n_i - np_i)^2}{p_i} + \frac{1}{p_N} (n_N - np_N)^2 \right\} = \\
 &= \sum_{i=1}^N \frac{(n_i - np_i)^2}{np_i} = \sum_{i=1}^N \left(\frac{n_i - np_i}{\sqrt{np_i}} \right)^2
 \end{aligned}$$

$$\begin{aligned}
 \sum_{i=1}^N n_i &= \sum_{i=1}^{N-1} n_i + n_N = n \\
 \sum_{i=1}^N np_i &= \sum_{i=1}^{N-1} np_i + np_N = n
 \end{aligned}$$



Equivalente a n variables poissonianas independientes



Ambos planteamientos son equivalentes

Finalmente los estimadores **LS** se obtienen minimizando la cantidad

$$\chi^2(\bar{\theta}) = \sum_{i=1}^N \frac{(n_i - np_i(\bar{\theta}))^2}{np_i(\bar{\theta})}$$

9. Mínimos cuadrados con datos clasificados

$$\chi^2(\bar{\theta}) = \sum_{i=1}^N \frac{(n_i - np_i(\bar{\theta}))^2}{np_i(\bar{\theta})} = \sum_{i=1}^N \frac{(n_i - f_i)^2}{f_i}$$

Igualando las derivadas a cero:

$$\frac{\partial \chi^2}{\partial \theta_k} = -2 \sum_{i=1}^N \left(\frac{n_i - f_i}{f_i} + \frac{1}{2} \left(\frac{n_i - f_i}{f_i} \right)^2 \right) \frac{\partial f_i}{\partial \theta_k} = 0 \quad k = 1, 2, \dots, m$$

Difícil solución analítica, se suele resolver numéricamente

Para valores de n grandes, el segundo termino se puede despreciar



$$\frac{\partial \chi^2}{\partial \theta_k} = -2 \sum_{i=1}^N \left(\frac{n_i - f_i}{f_i} \right) \frac{\partial f_i}{\partial \theta_k} = 0 \quad k = 1, 2, \dots, m$$

Mínimos cuadrados simplificado

Aproximar la varianza del número de entradas por el número de entradas

$$\chi^2(\bar{\theta}) = \sum_{i=1}^N \frac{(n_i - f_i)^2}{f_i} = \sum_{i=1}^N \frac{(n_i - np_i)^2}{n_i}$$

Más sencillo de manejar pero:

- Errores mal calculados
- Parámetros sensibles a fluctuaciones estadísticas

Para valores de n grandes, ambas formulaciones coinciden

9. Mínimos cuadrados con datos clasificados

En el límite asintótico de grandes números y siempre que $E[n_i] = np_i$ los valores de χ^2 se distribuyen como una distribución de:

$$\chi^2(N-1)$$



Se pierde un grado de libertad debido a la condición de normalización

$$\sum_{i=1}^N n_i = \sum_{i=1}^N np_i = n$$

Una vez minimizados, los valores de valores de χ^2_{\min} se distribuyen como $\chi^2(N-1-m)$ siempre y cuando el número de sucesos sea suficientemente grande como para suponer que:

$$\left(\frac{n_i - f_i}{\sqrt{f_i}} \right) \text{ y } \left(\frac{n_i - f_i}{\sqrt{n_i}} \right) \text{ se comportan gaussianamente}$$

¡Cuidado! Hay que tener en cuenta la anchura del bin w_i

Criterios para la elección del tamaño del bin

- Suele haber dos criterios:
 - a) Bines igualmente espaciados
 - b) Bines de igual probabilidad
- No se puede elegir el tamaño del bin para hacer que χ^2_{\min} sea lo más pequeño posible
- El número de entradas de cada bin ha de ser suficientemente grande para que las variables $(n_i - f_i)/\sqrt{f_i}$ y $(n_i - f_i)/\sqrt{n_i}$ sean gaussianas.
- En general se acostumbra a requerir al menos un mínimo de 5 entradas en cada bin

$$f_i = nw_i f(x_i; \theta)$$

10. Resumen propiedades

Comentarios sobre el método LS:

- Si la función f es lineal en los parámetros, hay solución analítica.
- En el caso lineal, los estimadores LS son *unbiased* y tienen varianza mínima.
- El valor de χ^2_{\min} proporciona información sobre la calidad del ajuste.

Ventajas

- Fácil de usar (implementar), incluso para muestras de datos muy grandes.
- Proporciona información sobre la calidad del ajuste (*Goodness-of-fit*).
- Método general para comparar dos distribuciones, datos vs. Teoría, etc.

Desventajas

- En caso de *binning* siempre hay una pérdida de información.
- Hay que ser cuidadosos con *bines* de pocas entradas.
 - Al menos ≥ 5 entradas, *bines* no vacíos.
 - De lo contrario, errores no gaussianos, distribución no es de χ^2
- En caso de correlaciones hay que utilizar la matriz de covarianzas.